Inteligencia Artificial

Conceptos iniciales (lista)

Inteligencia artificial & Sistemas inteligentes

Inteligencia artificial: rama de las ciencias computacionales que se encarga de estudiar modelos de cómputo (tecnologías, arquitecturas) para desarrollar software que sean capaces de realizar actividades propias de los seres humanos. Estas actividades tienen que ver con:

- El razonamiento;
- La conducta; y
- El aprendizaje

De alguna manera, la idea es construir software que se vaya mejorando con el uso y vaya tratando de aprender sola. A estas maquinas/software los vamos a llamar **Sistemas Inteligentes**.

Distintas disciplinas:

- IA tradicional
- Inteligencia computacional
- Aprendizaje automático (machine learning)
- Visión artificial
- Procesamiento del lenguaje material
- Big Data & Data Mining (aplican tecnologías que derivan de la IA)

Estas disciplinas nos permiten construir un sistema inteligente para resolver problemas. Estos problemas son especiales, de dominios complejos:

- El problema no se entiende completamente
- No se pueden anticipar todas las posibles situaciones ni los cambios futuros del ambiente
- La cantidad posible de soluciones es tan grande que no es viable llevar a cabo búsquedas exhaustivas
- Generar modelo tradicional que lo resuelva debe ser simplificado tanto que la solución deja de ser útil

Los datos de los sistemas inteligentes tienen significado y utilidad.

¿Qué son los sistemas inteligentes?

Son artefactos que tengan algún tipo de comportamiento inteligente. ¿Qué es un comportamiento inteligente?

- Pueden tomar decisiones consistentes con su objetivo (son racionales)
- No poseen todos los conocimientos ni todos los datos (no son omniscientes)
- No siempre son exitosos (no son infalibles)
- Pueden mejorar durante su uso (pueden aprender)
- Soportan a cambios del dominio (pueden ser flexibles y robustos)

Para desarrollarlos, tenemos a la IA tradicional y la Inteligencia Computacional & Machine Learning

IA Tradicional: sistemas inteligentes basados en reglas, métodos heurísticos y lógica.

Inteligencia computacional: sistemas inteligentes basada en inspiración biológica (como los algoritmos genéticos) +:

Machine learning: sistemas que pueden aprender a partir de ejemplos

Tipos de sistemas inteligentes

Podemos considerar cual es la base de conocimientos y cuál es la tecnología a implementar.

Fuentes de conocimientos:

- Fuentes públicas: fuentes que están explicitadas (no implica que sean gratuitas), son accesibles de manera digital
- Fuentes privadas: es todo conocimiento y datos que están interiorizados en la mente de una persona

En el caso que usemos como fuente de conocimiento una privada, estaríamos desarrollando un **Sistema Experto (SE)**. Que es un sistema cuyas prestaciones intentan emular parte del comportamiento de un experto humano para resolver ciertas tareas en un dominio determinado.

Es importante notar que un sistema experto también puede usar fuentes públicas, el ser experto no significa que únicamente deban ser fuentes privadas.

En el caso de un sistema inteligente, será solo de fuentes públicas.

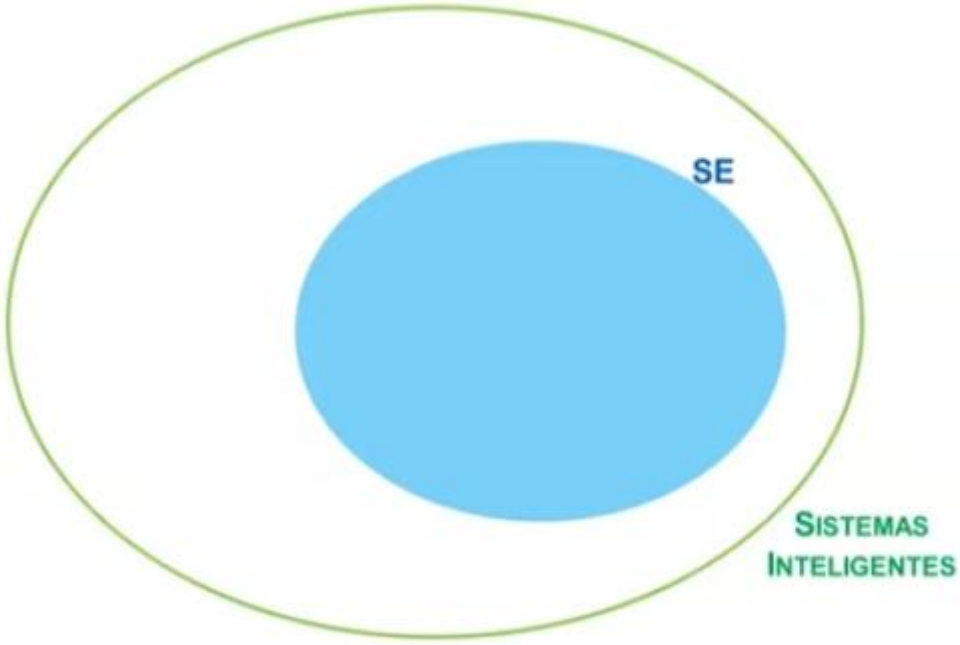

Un sistema inteligente no siempre es un sistema experto, pero un sistema experto siempre es un sistema inteligente.

Familias de tecnologías:

- ➔ IA Tradicional
- ➔ Inteligencia computacional & Machine Learning

La IA tradicional propone la implementación de Sistemas Inteligentes basados en reglas, heurísticas y lógica. Sus prestaciones dependen mas de la presencia explicita de un cuerpo de conocimientos que de la posesión de ingeniosos procedimientos computacionales.

Desde el punto de vista de los Sistemas basados en conocimientos (SBC), tenemos reglas y hechos que provienen de fuentes públicas, un motor de inferencias y por ultimo una interface de entrada/salida.

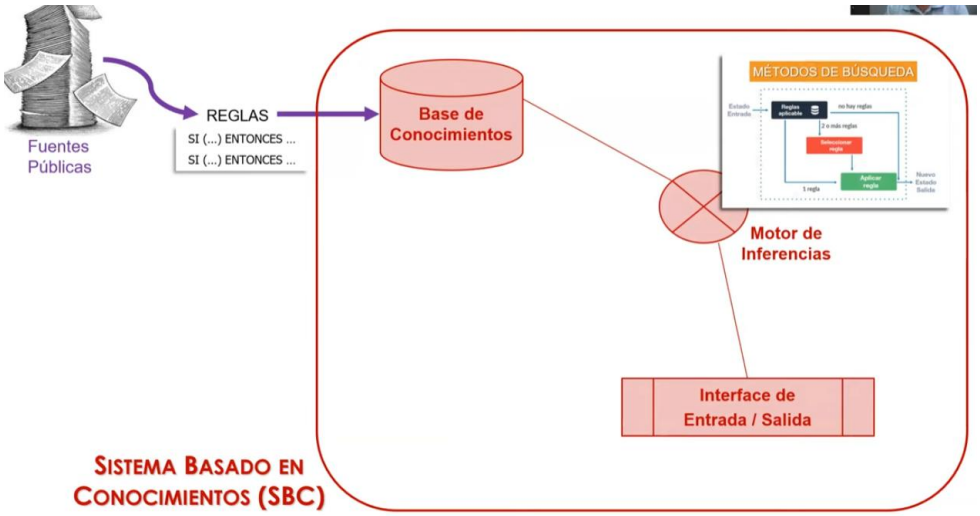

Por otro lado tenemos los Sistemas Expertos Tradicionales (SET). Son tradicionales porque tienen una base de conocimientos. Además, utiliza fuentes privadas, y a la interface de E/S la llamamos Manejador de Comunicaciones.

Aparecen algunos componentes adicionales, como la base de datos, que almacena la información del problema que yo quiero resolver. También existe la memoria de trabajo, que permite registrar toda la traza de reglas, pasos que uso el motor de inferencia para resolver el problema. Esta memoria es útil porque tenemos al Trazador de Explicaciones, que permite justificar el resultado que genera el SET. Por ultimo, el trazador de consultas, permite solicitarle al usuario información adicional sobre el problema que quiero resolver, y le va a explicar porque necesita esa información.

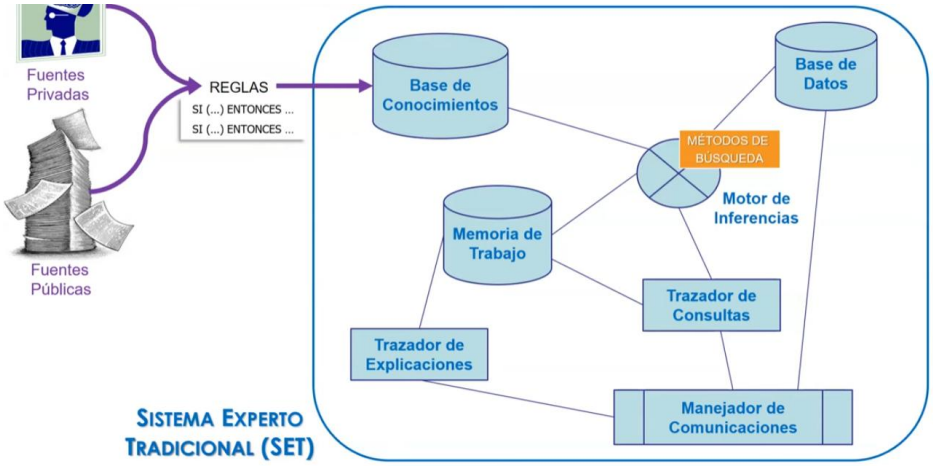

En cuanto al grupo de **Inteligencia Computacional**, algunos ejemplos son las redes neuronales artificiales, computación evolutiva, inteligencia de enjambre, sistemas inmunológicos artificiales, entre otros. Todos con inspiración biológica.

Y en cuanto a **Machine Learning** son los algoritmos que pueden aprender a partir de ejemplos.

Clasificación de sistemas inteligentes

Según la tecnología

- IA tradicional: SBC, SET, Lógica difusa
- Machine learning: Lógica difusa, Algoritmos de inducción y regresión, Redes neuronales artificiales
- Inteligencia computacional: Redes neuronales artificiales, Algoritmos genéticos

Según los conocimientos

- Fuentes públicas: todas

- Fuentes privadas: Sistema experto

Introducción al aprendizaje automático

En general, un algoritmo de ML recibe un conjunto de datos y como salida nos da un modelo que podemos usar en un SI.

"Genera un software que es 'automáticamente' capaz de adquirir capacidades y adaptarse a su entorno."

En los algoritmos de ML tenemos distintas estrategias de aprendizaje:

- ➔ Supervisado: al algoritmo le damos, además de los ejemplos, información adicional para que pueda encontrar la relación/patrón que le permita resolver el problema.
- ➔ No supervisado: le damos solo ejemplos de entrada.

También, distintos tipos de entrenamiento:

- ➔ Offline (o estático): son algoritmos que tienen una fase de entrenamiento en la cual aprende para generar el modelo, y luego de la instalación no aprenden más y pasan a fase de operación.
- ➔ Online (o dinámico): tenemos la fase de entrenamiento, pero en la fase de operación puede seguir aprendiendo nuevos conocimientos.

A su vez, hay distintos tipos de algoritmos:

- ➔ De clustering
- ➔ De inducción
- ➔ De regresión
- ➔ Basados en Bayes
- ➔ Redes neuronales artificiales
- ➔ ...

Algoritmos de inducción

Ejemplo clásico de los algoritmos supervisados de ML. Tienen como función identificar un conjunto de reglas que permiten clasificar de manera similar a los ejemplos que uno le da al algoritmo. Para funcionar, requiere que los datos estén estructurados en forma de tabla.

"Filas: ejemplos, Columnas: atributos", se aplican en el algoritmo para identificar las reglas. En las reglas las condiciones del antecedente van a estar formados por los atributos de entrada (no todos, algunos), y en el consecuente vamos a tener los distintos valores del atributo objetivo (que siempre es uno solo)

Una vez definido lo anterior, podemos usar el algoritmo que va a definir las reglas.

Algoritmos TDIDT: generan arboles de decisión a través de una inducción de arriba hacia abajo. Usa una filosofía de divide y vencerás.

A partir de un conjunto de datos T:

- Si T está vacío -> finalizar
- Si T tiene un único valor en el atributo objetivo -> Generar hoja
- Sino
    1) Seleccionar atributo de entrada con mayor ganancia en T
    2) Particionar T por cada valor del atributo de entrada seleccionado
    3) Para cada partición de T, aplicar nuevamente el proceso.

Algoritmos de regresión

Clásicos de ML. A partir de una tabla, puedo identificar una fórmula que describa la relación entre los valores que toman los ejemplos de dicha tabla.

A partir de un conjunto de datos estructurados con distintos atributos y un atributo objetivo y varias filas/ejemplos voy a poder generar una fórmula que describa la relación entre los atributos de entrada y el atributo objetivo. Será necesario que los atributos de entrada y el objetivo van a tomar valores NUMÉRICOS. En caso de no tenerlos, en un paso previo se deben transformar.

ML: procesos de construcción

Entrenamiento: proceso que buscar determinar (aprender) los valores correctos para construir un modelo que representa un conjunto de datos disponibles (ejemplos)

El ingeniero debe asegurar que el modelo aprendió correctamente, para eso debe ejecutar otros dos procesos: validación y prueba.

Validación: proceso que consiste en evaluar los resultados de diferentes parámetros en el entrenamiento para intentar optimizar el modelo obtenido. Generalmente se ejecuta en paralelo al entrenamiento.

Prueba: proceso que buscar evaluar si el modelo construido posee una buena capacidad de “generalización”.

Entonces, necesitaré distintos conjuntos de datos: de entrenamiento, de validación, de prueba.

En el proceso de pruebas, tengo que disponer de un conjunto de métricas para evaluar el modelo.

Ellas son:

ENTRENAMIENTO CON APRENDIZAJE SUPERVISADO PARA VALORES DE SALIDA DISCRETOS

- Matriz de confusión: ¿en qué medida se genera la salida correcta para los datos de entrada ingresados? (medir la 'CONVERGENCIA' del modelo)

		Clase Modelo	
		Sí	*No*
Clase Problema	*Sí*	Verdadero Positivo	Falso Negativo
	No	Falso Positivo	Verdadero Negativo

  Problema: si hay muchos ejemplos, se complica (ejemplo: provincias, 24 filas y 24 columnas)
- Exactitud (Accuracy): indica la proporción de identificaciones que el modelo realizó correctamente. E = (VP+VN)/(VP+FP+VN+FN)

		Clase Modelo	
		Sí	*No*
Clase Problema	*Sí*	VP	FN
	No	FP	VN

- Precisión: indica la proporción de clases identificadas como positivas que son correctas. P = VP/(FP+VP)
- Recuperación (exhaustividad o recall): indica la proporción de clases positivas reales (fila) identificadas correctamente. R = VP/(VP+FN)

Cuanto mayor valor tengan, mejor funciona el modelo.

- Una buena EXACTITUD no significa que el modelo sea confiable.
  1) Sobretodo cuando hay un desequilibrio por una gran desproporción entre los ejemplos positivos y negativos
- Pero, mejorar la precisión generalmente perjudica la recuperación, y viceversa
  1) F1 Score (FScore o Fmeasure):
     - Indica la exactitud real del modelo combinando su precisión y recuperación. F1 = 2*(P*R)/(P+R) ó Fβ = (P*R)/(β^2*P+R)

ENTRENAMIENTO CON APRENDIZAJE SUPERVISADO PARA VALORES DE SALIDA CONTINUOS

- Error absoluto: indica la diferencia absoluta entre el valor real (o correcto) y el valor estimado por el modelo Err_abs=|r-e|
- Error relativo: indica el porcentaje de error generado por el valor estimado. Err_rel=|r-e|/r=Err_abs/r

Cuanto menores son los errores, mejor es el modelo

Análisis de protocolos (lista)

Cuando realiza una tarea, el individuo verbaliza o "piensa en voz alta" todo lo que le pasa por su cabeza, obteniéndose un protocolo verbal grabado.

Es una técnica para revelar lo que saben los expertos en un determinado dominio donde se le pide al experto que piense en voz alta mientras efectúa la tarea.

La gran ventaja de los protocolos es obtener información sobre procedimientos que el experto utiliza en la resolución de problemas pero no puede verbalizar en forma consciente.

Etapas del análisis de protocolos

- Grabación del protocolo
- Transcripción
- Codificación
- Interpretación

Grabación del protocolo

1) El Ingeniero en conocimientos (IC) explica lo que espera del experto
    a. Objetivo de la técnica: obtener conocimiento de como el experto razona al momento de efectuar una tarea
    b. Informar todo lo que piensa en el momento de la resolución
    c. Instrucciones sobre qué es lo que debe hacer. Si se quedara callado, lo interrumpimos para recordarle que comunique.
2) Puesta en situación
    a. Proponer pequeños ejercicios
    b. Objetivo: darle confianza al experto
3) Registro del protocolo
    a. Grabación propiamente dicha. Siempre es muy importante perseguir el objetivo del protocolo.

Transcripción

El IC escucha la grabación y TRANSCRIBE el protocolo SEGMENTÁNDOLO

No hay una manera mejor que otra para segmentar.

Al resultado de la transcripción se le adjuntan anotaciones que hizo el IC por sobre las acciones del experto (si leyó un libro, busco información en internet, etc)

Codificación

1) Identificación de conceptos, características, valores, relaciones y operadores
2) Identificación de la búsqueda
3) Identificación de sinónimos, metacomentarios e incertidumbres

Subetapa 1:

Conceptos, Características, Valores. Podemos hacer una analogía con un DER.

Concepto -> Entidad

Características -> Un concepto tiene características, es decir atributos propios

Valores -> Dichos atributos propios tienen valores.

Pueden haber relaciones entre conceptos, entre conceptos y características, y entre valores y características.

Operadores: medios que el operador usa para pasar de un estado del problema a otro más próximo de la solución.

1	El **paciente**
2	**presenta** **fiebre** **superior a 38**,
3	**manifiesta** un **fuerte** **dolor de garganta** y
4	**tos** **seca**.

Este lo podemos analizar como:

paciente	Concepto
presenta	Relación
fiebre	Característica
superior a 38°	Valor
manifiesta	Relación
fuerte	Valor
dolor de garganta	Característica
tos	Característica
seca	Valor

5	Su **frecuencia respiratoria** es **muy elevada** y
6	**tiene dolores musculares intensos**.
7	Podríamos pensar,
8	**que estamos ante un**
9	**coronavirus COVID-19**

Este lo podemos analizar como:

frecuencia respiratoria	Característica
muy elevada	Valor
dolores musculares	Característica
intensos	Valor
que estamos ante un	Operador
coronavirus COVID-19	Concepto / Valor

10	El paciente
11	debe permanecer aislado por precaución
12	dado lo contagioso del virus.
13	En una segunda observación,
14	**vemos que** esta **persona**
15	**presenta dolor de cabeza persistente** y
16	**sufrió un mareo repentino** de **larga duración**.

vemos que	Relación
persona	Concepto
presenta	Relación
dolor de cabeza	Característica
persistente	Valor
sufrió un	Relación
mareo	Concepto
repentino	Valor
duración	Característica
larga	Valor

El mareo no puede ser una característica, ya que por un lado tiene un “tipo” (es repentino) y por el otro tiene una duración.

17	El **análisis de laboratorio**
18	**dió un resultado positivo al virus H1N1**.
19	**Concluimos que se trata de una**
20	**gripe clase A**.

análisis de laboratorio	Concepto

dió un	Relación
resultado	Característica
positivo al virus H1N1	Valor
concluimos que se trata de una	Operador
gripe clase A	Concepto / Valor

Una vez terminado, podemos armar la tabla de conceptos-características-valores

Si considero los estados como conceptos

Conceptos	Características	Valores
paciente	fiebre	superior a 38°
	dolor de garganta	fuerte
	tos	seca
	frecuencia respiratoria	muy elevada
	dolores musculares	Intensos
	dolor de cabeza	persistente
coronavirus COVID-19		
persona		
mareo	(tipo)	repentino
	duración	larga
análisis de laboratorio		
gripe clase A		

La característica entre paréntesis es una del tipo implícita, que el experto no la dice pero que existe, y deberemos preguntar al experto si esa característica está bien.

Los conceptos considerados como estados no deben tener características ni tampoco otros conceptos considerados como sinónimos.

Si considero los estados como valores

Conceptos	Características	Valores
paciente	(diagnóstico)	coronavirus COVID-19
		gripe clase A
	fiebre	superior a 38°
	dolor de garganta	fuerte
	tos	seca
	frecuencia respiratoria	muy elevada
	dolores musculares	Intensos
	dolor de cabeza	persistente
persona		
mareo	(tipo)	repentino
	duración	larga
análisis de laboratorio	resultado	positivo al virus H1N1

Puedo considerarlos como uno prefiera, pero solo uno de los dos a la vez...

Una vez terminada la tabla pasamos a ver las relaciones implícitas (SOLO entre conceptos)

- *Si considero los estados como conceptos*

paciente –tiene→ coronavirus COVID-19

–tiene→ gripe clase A

paciente –sufre de→ mareo

–se realiza→ análisis de laboratorio

- *Si considero los estados como valores*

paciente –sufre de→ mareo

–se realiza→ análisis de laboratorio

No existen relaciones implícitas entre sinónimos.

Subetapa 2 (identificación de la búsqueda)

Identificar estados por los que el experto pasó, que operadores utilizó y cuales son las condiciones para llegar a estos estados.

Subetapa 3 (identificación sinónimos, metacomentarios e incertidumbres)

Sinónimos → paciente y persona

Metacomentario: son aquellos comentarios que el experto hace que no aportan una información directa a su razonamiento. La manera de identificarlos es por las líneas en las que están, el metacomentario propiamente dicho y su significado.

Líneas	Metacomentario	Significado
[10-12]	el paciente debe permanecer aislado por precaución dado lo contagioso del virus	hace referencia a lo contagioso que es el coronavirus COVID-19
13	en una segunda observación	Subetapas

Incertidumbre: “podríamos pensar”. Son aquellas nociones donde el experto le asigna una duda en cuanto al <u>cambio de estado</u>.

Interpretación

Identificar las reglas de razonamiento del experto. Para hacerlo, lo hacemos con un pseudocódigo. SI (condiciones) ENTONCES (acciones)

Las condiciones serán de tipo “concepto.caracteristica = valor”

En nuestro ejemplo:

SI (paciente.fiebre = superior a 38°) y
(paciente.dolor de garganta = fuerte) y
(paciente.tos = seca) y
(paciente.frecuencia respiratoria = muy elevada) y
(paciente.dolores musculares = intensos)

ENTONCES asignar (diagnóstico, coronavirus COVID-19)

SI (paciente.dolor de cabeza = persistente) y
(mareo.tipo = repentino) y
(mareo.duración = larga) y
(análisis de laboratorio.resultado = positivo al virus H1N1)

ENTONCES asignar (diagnóstico, gripe clase A)

En las reglas de la gripe clase A no tenemos las otras características porque siempre se las considera de forma atómica, es decir una regla no se relaciona con otra regla. En etapas posteriores, se pueden empezar a relacionar reglas.

Algoritmos genéticos (lista y esta otra)

Los algoritmos genéticos son algoritmos matemáticos de optimización de propósito general basados en mecanismos naturales de selección y genética, proporcionando excelentes soluciones en problemas complejos con gran número de parámetros.

Paralelismos entre teoría de la evolución y AG

Teoría de la evolución	**Algoritmos genéticos**
Ecosistema / Ambiente	Problema
Individuo	Posible solución
Genotipo / Cromosoma	Descripción de la solución
Gen	Característica o Atributo
Fenotipo	Función de Aptitud

Las fases son:

- Generar población inicial

- Selección
- Cruzamiento
- Mutación
- ¿paro?
    1) Si -> población final
    2) No -> vuelvo a Selección

Lo subrayado lo denominamos “vuelta” o “ciclos”, mientras que todo el procedimiento es una “corrida”.

Genotipo / Cromosoma: es una cadena de bits, donde debemos identificar que porción de esa cadena va a formar un Gen y cada Gen le atribuimos una característica (no todos los genes deben tener la misma longitud).

Fenotipo / Función de aptitud: f(x) → R, determina que tan apto es el cromosoma como solución.

Operadores (S, C, M, ‘opcional GPI, P’)

Generar población inicial

- Método
    1) Al azar
    2) Ad-hoc
- Población
    1) Cantidad de individuos
    2) Varianza
        - Constante
        - Variable

Selección

Torneo

Juntar la población de a pares y los comparamos mediante la función fitness (de aptitud). Pueden aparecer los mismos individuos más de una vez, y pueden ganar más de una vez.

Desventajas: si hago pelear al mejor contra el segundo mejor, pierdo el segundo mejor si este último no participa en otra pelea.

Ranking

Tomar la población inicial y armar una población ordenada, en base a esto, voy tomando los individuos que quiera. Desventaja: nunca hago participar a los malos, lo que puede llevar a una convergencia prematura, que es quedarse anclado en un máximo local.

Ruleta

Es un método más completo. A todos los individuos los evaluamos con la función de aptitud y los sumamos, y luego hacemos el cálculo del porcentaje de proporción de pertenencia que tienen. A partir de esto, calcular la probabilidad acumulada (para el primer caso, es el mismo valor, y luego voy acumulando en los de abajo, sumando su proporción).

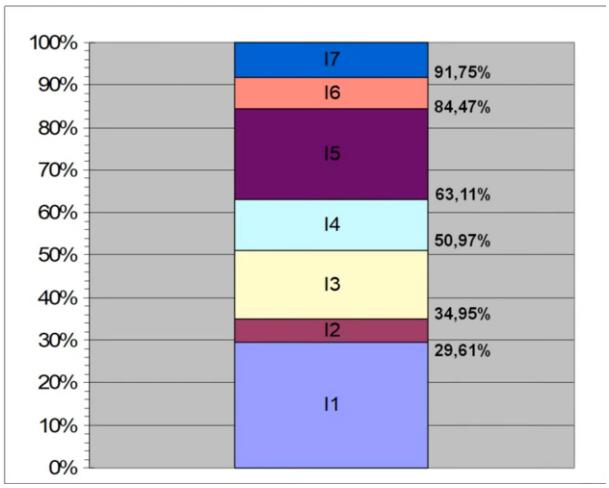

Dispongo los cálculos en un paño y voy tirando randoms, donde los más aptos tienen más probabilidad, pero no le quito la chance a los demás.

Control s/nro. esperado

La ruleta tiene de malo que a veces pueden salir todos malos, entonces para eso existe este método

a) Preselección de los mejores: calculamos el promedio (Suma de func. fitness / Total individuos), y luego calculamos la relación entre la función fitness y el promedio. La parte entera del resultado es la cantidad de veces que tomaré al individuo y hago ruleta de nuevo.
b) Selección por ruleta: creamos una nueva función fitness, que es la mantisa de la relación entre la función fitness y el promedio.

Cruzamiento

Lo realizamos sobre los individuos seleccionados. Es realizar una actividad de a pares y generar descendencia.

Simple

Se tienen 2 padres (X Y) y se obtienen 2 hijos (A B). Se establece un punto de corte y se cruzan desde ese. No se debería cortar por medio de un gen para evitar errores.

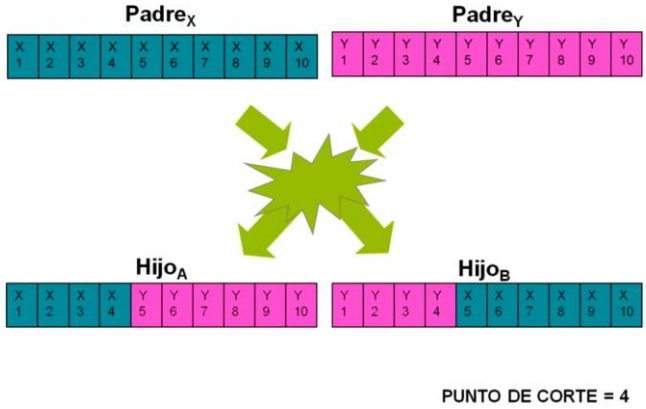

Multipunto

Se puede poner más de un punto de corte y se hace lo mismo.

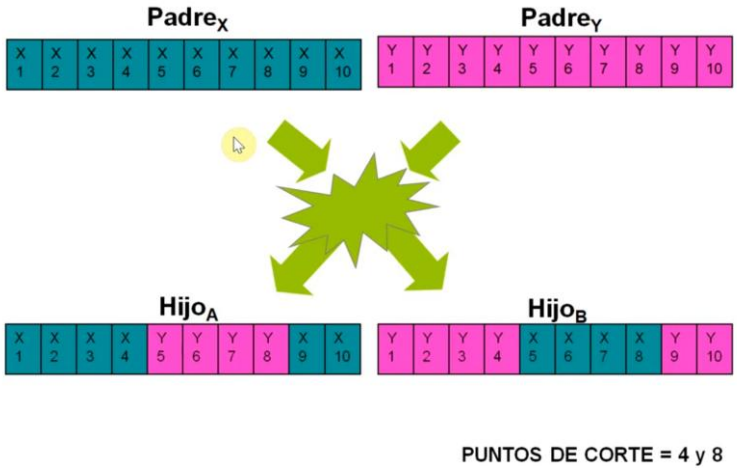

En estos métodos la característica de un padre que va hacia un hijo no va para el otro hijo.

Binomial – Máscara complemento

Se define una máscara y esas características van para un hijo, y el complemento de la máscara va para el otro.

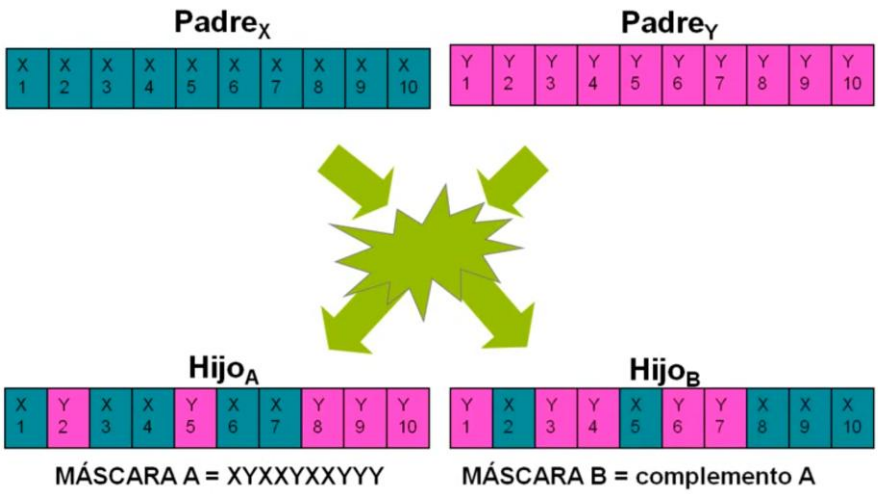

Es como hacer una cruza multipunto

Binomial – Máscara doble

En este método se pueden repetir características de un padre. Hay una máscara para cada uno de los hijos.

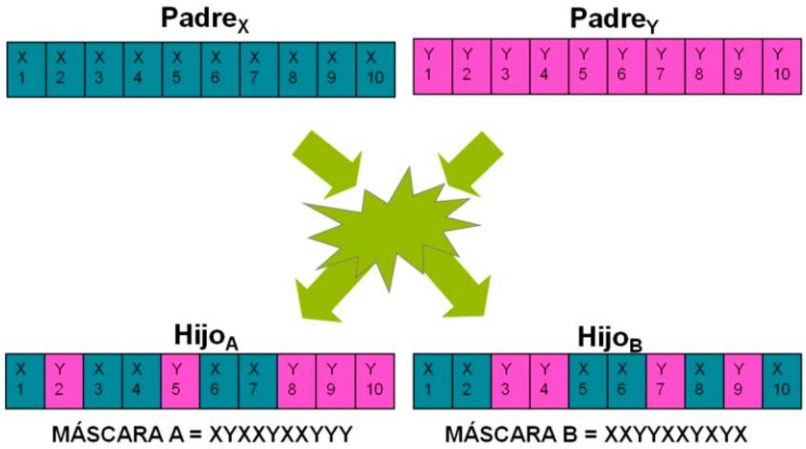

Binomial – Azar

Definimos un random, si R<=M uso a X, si R>M uso Y.

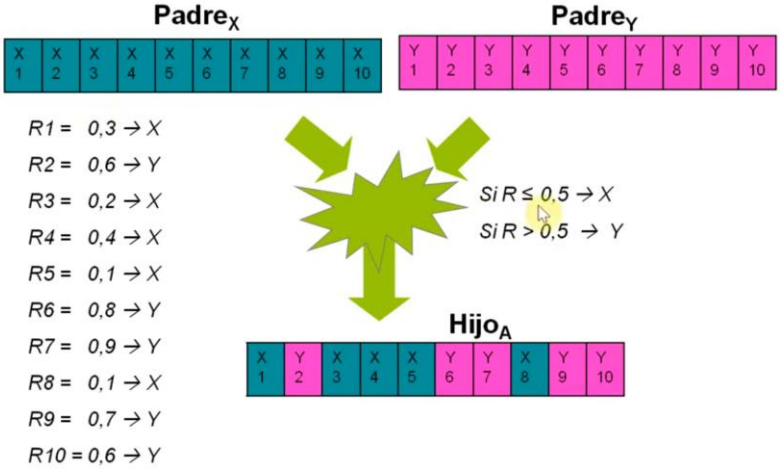

Para el otro hijo tenemos las opciones de tomar el complemento del resultado anterior, o bien volver a tomar al azar.

Mutación

Se da después del cruzamiento, y es dar la posibilidad de tener alteraciones cromosómicas en el individuo debido a algún agente exógeno.

En este caso es cuando cambia una posición del cromosoma del gen de un individuo (a veces, no siempre). La mutación se activa pero no necesariamente se ejecuta.

Para decidir si ejecutamos la mutación, se define una probabilidad de mutación, se tira un random y ahí decido.

Si la población no muta, la población cruzada es igual a la población mutada.

Si la población muta se genera otro random “de posición” y la posición elegida es la que vamos a cambiar de valor.

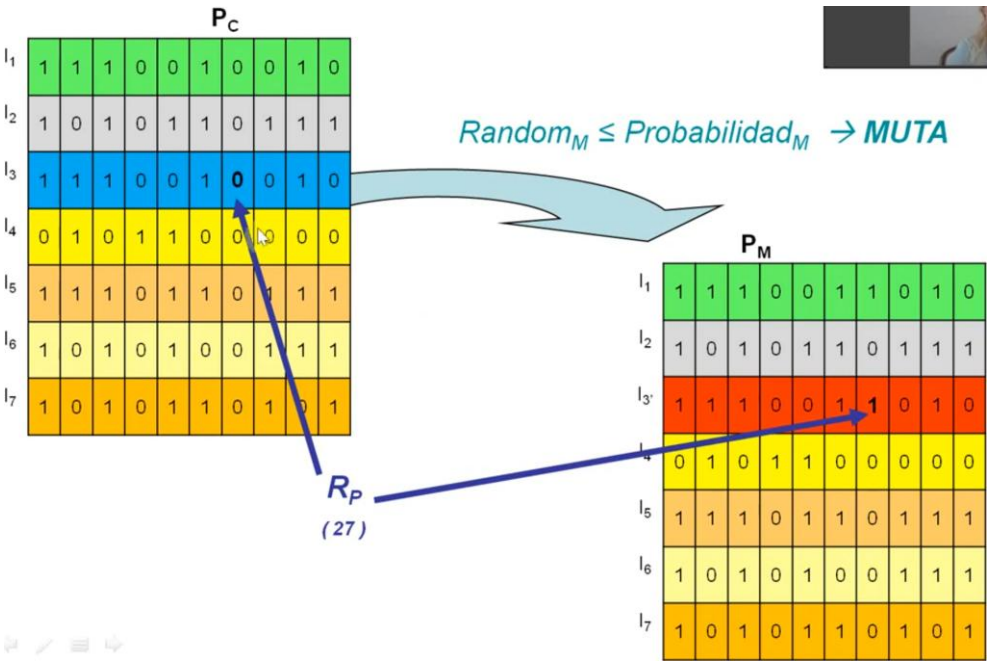

Métodos de mutación

- Simple
  Probabilidad_M = constante → en la corrida la probabilidad no cambia
- Adaptativa por convergencia
  Probabilidad_M = G { Promedio [f(Ix)] }
- Adaptativa por temperatura
  1) Ascendente
  2) Descendente
     Probabilidad_M = G(cantidad de vueltas)

Criterio de paro

- Cantidad de vueltas
- Tiempo transcurrido
- F(Ix) > Valor
- Promedio [f(Ix)] ≈ Valor
- ...

Para las dos ultimas, hay que tener cuidado de no iterar infinitamente.

Si el criterio de paro no se cumple, iteramos de nuevo y la “nueva población inicial” es la población mutada.

Identificación del individuo solución (teoría)

Se ejecuta la función fitness a los individuos de la población y se elige el mejor. Decodificamos el cromosoma y lo interpretamos.

En la práctica, se tienen logs de distintas corridas y de todos los logs buscar el mejor individuo.

Redes neuronales artificiales (lista)

Es un tipo de sistema experto. La podemos relacionar con inteligencia computacional, ya que tiene inspiración biológica; y con ML en las características que tienen para aprender de manera automática.

Una RNA es la evolución de un sistema de cómputos basado en un modelo biológico. El cual está formado por la combinación de elementos simples de proceso interconectados que operan en forma paralela para cumplir un objetivo.

Ventajas

- Aprendizaje adaptativo: una RNA tiene un periodo de entrenamiento en el que va recolectando la información que proviene de datos y ejemplos que suministramos, y a partir de estos intenta encontrar un patrón que le permita resolver el problema. Es adaptativo porque una RNA puede aprender casi cualquier tipo de problema
- Autoorganización: durante su entrenamiento va a cambiar la forma en que las distintas neuronas se van a interconectar entre sí
- Tolerancia a fallos: tienen flexibilidad (tiene un límite tampoco puede aprender en base a ejemplos muy distintos de los que se les suministró)
- Operación en tiempo real
- Fácil inserción en tecnología existente

Neurona artificial

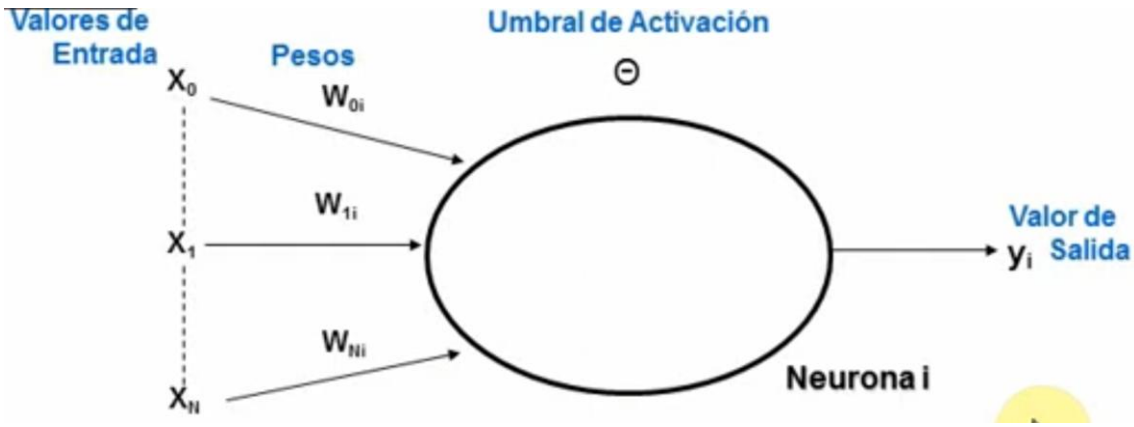

Los valores de entrada son un valor numérico. A cada entrada lo afecta los pesos de las conexiones, que también son valores numéricos y representan el tipo de sinapsis que va a tener cada conexión de mi neurona.

A partir de esto se calcula la Entrada neta: Net_i = Suma (Wji * Xj)

A esta entrada neta la afecta una función o regla de activación, que es una función matemática que utiliza la entrada neta y el umbral de activación para determinar si mi neurona se activa o no. El umbral puede ser fijo o variable.

Por ultimo tenemos una función de salida o transferencia que determina el valor de salida Y (numérico) a partir del resultado de la función de activación.

S[A (Net_i)] = Yi

La salida es única, pero puede ser que se multiplexe en varias conexiones con otras neuronas.

Una RNA es una red que interconecta neuronas artificiales.

Componentes de RNA

- Unidad de proceso -> neurona: se pueden ubicar en distintas capas o niveles. La primer capa la consideramos de entrada, mientras que la ultima es la de salida. Las capas entre el medio de estas dos se denominan de procesamiento u ocultas.
- Conexión → Wij sinapsis >0 excitadora, = 0 neutra, < 0 inhibitoria
  Entrada neta.

Modelo RNA

Dependerá del problema a resolver.

Tipo de información de E/S

Representación de información de E/S:

- Discreta – Binarios (0/1)
- Continua – Reales

Función o regla de activación. A(Net_i)

- Escalón
- Identidad
- Lineal mixta
- ReLU
- ...

Función de salida o transferencia. S [A (Net_i)]

- Escalón
- Mixta
- Sigmoidal
- Gauss
- ...

En la práctica se suele simplificar utilizando una única función que combina ambas:

F (Net_i) = S [A (Net_i)] = y_i

Tipo de asociación de información de E/S

- Heteroasociativas (AI, BI): aplica aprendizaje supervisado. Le suministro a la red un conjunto de patrones de entrada y una salida deseada. Lo que quiero es que mi red aprenda a asociar los datos de entrada con la salida.
- Autoasociativas o asociativas: el aprendizaje es no supervisado. Le suministro datos de entrada y la red sola aprende a identificar la salida correcta.

Topología

- Cantidad de capas: Monocapa o multicapa.
- Cantidad de neuronas por capa
- Tipo y grado de conectividad: Total o parcial. Cuando es total todas las neuronas se conectan con todas las neuronas de la siguiente capa
- Formas de conexión
    1) Propagación hacia adelante
    2) Propagación hacia atrás
        - Entre neuronas de la misma capa
        - Recursivas: salida de una neurona es su misma entrada
        - Neurona de una capa le manda su salida como entrada a una neurona de una capa anterior

Reglas de aprendizaje o estrategias de entrenamiento

- Supervisado: necesitan un ente externo que suministran información extra. Se usa en heteroasociativo. Clasificar datos o predecir
- No supervisado: autoasociativas. Problemas de clustering, clasificación automática, completar patrones incompletos.
- Offline: una fase de entrenamiento ANTES de producción y en producción deja de aprender
- Online: aprende antes y durante producción.

En una RNA solo se modifican los pesos en las conexiones de las neuronas

Combinando tenemos

Supervisado offline:

- Por corrección de error
- Estocástico: similar a corrección de error pero ajusta los pesos aplicando cambios al azar (hoy día no se utiliza mucho)

Supervisado online:

- Por refuerzo: similar a corrección de error pero ajusta los pesos considerando solo la valoración de la salida generada

No supervisado offline/online:

- Hebbiano
- Competitivo/cooperativo: basado en dos etapas (1) ordenación global (2) ajuste fino → clustering

Subrayado se ve más adelante

Perceptrón

RNA heteroasociativa, con aprendizaje supervisado off-line con la estrategia de corrección de errores. Es una única neurona (monocapa).

La corrección de errores está basado en el Aprendizaje por repetición, que es repetir varias veces una misma tarea.

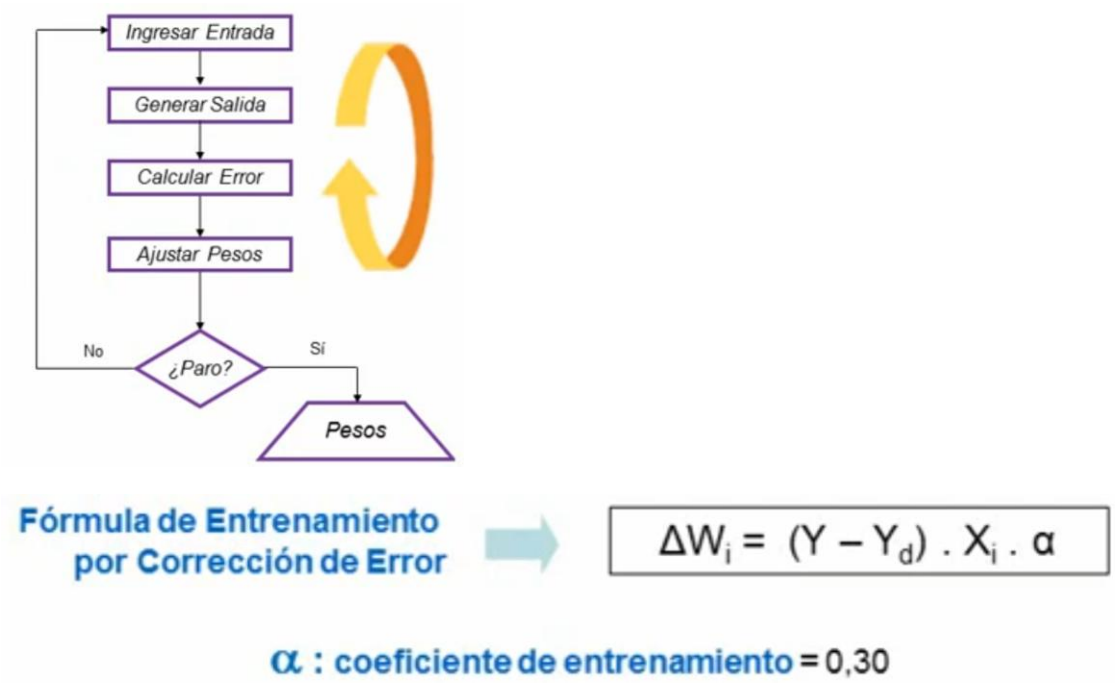

Con el alfa, intento evitar que perceptrón se olvide lo que aprendió. El aprendizaje tardará más pero es menos propenso a olvidar.

Recomendaciones:

- El valor del umbral se puede ajustar como si fuera un peso más, pero para mayor estabilidad del proceso de aprendizaje, se suele mantener constante.
- Se suele trabajar solo con valores binarios, normalizando los valores de entrada y de salida en el rango [0; 1].
- Es conveniente utilizar un coeficiente de entrenamiento (alfa) ente 0,05 y 0,30.
- Normalmente se usan valores de los pesos iniciales (w_i) entre 0,00 y 0,50.

Desventajas

Aunque se puede utilizar para aproximar casi cualquier tipo de función lineal, nunca podrá aprender funcionar no-lineales.

RNA Multi-perceptrón con regla delta generalizada

(o gradiente decreciente) o de aprendizaje por retropropagación del error.

Es una RNA heteroasociativa, con aprendizaje supervisado off-line con corrección de errores. Es multicapa.

Sus principales aplicaciones son:

- Clasificación de datos
- Estimación o predicción de resultados.

Los parámetros de la red:

- Función de Activación y Salida combinada

$$F(Net) = \frac{1}{1 + e^{-(Net - \Theta)}} = \frac{1}{1 + e^{-\left[\sum (w_{jk} \cdot x_{jk}) - \Theta_k\right]}}$$

Las funciones que usemos deben ser derivables (en este caso se usó la función sigmoidal)

- Tiene una función de salida
- Factor de aprendizaje “el alfa”
- Umbrales de neuronas
- Pesos iniciales

Para entrenar, si se tiene que corregir un error, se propaga el error hacia atrás. Se usa el gradiente del error (delta_e)

Recomendaciones

- Normalmente se utiliza la función Sigmoidal, sobre todo en el caso que los valores de entrada y de salida sean binarios.
  Para manejar valores reales, es posible utilizar la función Gaussiana o la tangente hiperbólica
- Puede aproximar casi cualquier tipo de función lineal o no lineal, pero puede pasar que nunca aprenda (por caer en un mínimo local).

  En ese caso, se debería probar:
  1) Normalizar los datos de E/S
  2) modificar los parámetros de aprendizaje
  3) utilizar otros pesos iniciales
  4) modificar el orden en que se ingresar los patrones
  5) añadir neuronas ocultas y/o capas
  no hay regla general para definir la cantidad de capas ni de neuronas a utilizar.

En la normalización de los datos se usa el promedio y la varianza.

Una aclaración importante es que si normalizamos los datos, en producción los debemos también normalizar.

La tasa de aprendizaje:

- Conviene utilizar valores entre 0,05 y 0,30:
  1) Más grande → parálisis o inestabilidad (esquivará al óptimo)
  2) Más pequeña →demasiada lentitud en el aprendizaje
- Usar tasa adaptativa (decreciente, para evitar máximos locales)
- Buena aproximación es usar: 1/F''(x)

Además, se recomienda que los pesos iniciales se inicialicen entre 0 y 0,5

Definir cantidad de cciclos para el entrenamiento:

- Pocos ciclos → aprendizaje no acabado
- Demasiados ciclos → sobreaprendizaje
- Adaptativo de acuerdo al error de entrenamiento y validación

Especificar la topología de la red:

- Neuronas de entrada, dependen de los datos de entrada
- Neuronas de salida, idem anterior
- Neuronas de ocultas: a mayor cantidad de neuronas y de capas, la RNA posee mayor capacidad de aprendizaje y complejidad, por lo que aumenta el tiempo de aprendizaje.

1) Una capa oculta suele ser suficiente para la mayoría de problemas
2) Dos niveles de capas ocultas hacen que la red aprenda más rápido (para la misma cantidad de neuronas)
3) Manual (prueba y corrección)
4) Automático usando algoritmos genéticos, fórmulas o herramientas

Métricas para evaluar la RNA

- Matriz de confusión: medir la convergencia del modelo. Ver cantidad de verdaderos positivos y negativos, y falsos positivos y negativos.
- La matriz + exactitud + precisión + recuperación (que se vieron más arriba)

RNA Hopfield

Es RNA autoasociativa, usa aprendizaje no supervisado off-line con hebbiano. Es monocapa

Las neuronas tienen conexiones laterales.

Se usan matrices para el entrenamiento. Se multiplica el vector resultado por el vector traspuesto y tachamos la diagonal. Esta es la matriz de pesos. Hacemos esto por cada patrón, y luego para saber el peso de la red, hacemos la suma de los pesos de cada patrón.

Consideramos que el modelo aprendió cuando en dos "ciclos" seguidos obtenemos el mismo resultado.

Observaciones

- Se suele utilizar para completar los valores faltantes en patrones de entrada a partir de patrones ya aprendidos (identificación de patrón o clasificación)
- Para una red de N neuronas, posee las siguientes limitaciones:
    1) Los patrones a memorizar deben ser ortogonales, es decir, deben ser diferentes uno de otro en N/2 componentes
    2) En general, puede almacenar y recuperar

sin error

$$\leq \frac{N}{4\ln(N)} \text{ patrones}$$

con mínimo error

$$< 0{,}15N \text{ patrones}$$

Comparación de modelos de RNA

<table>
<tr><th>Característica</th><th>Perceptrón</th><th>Back propagation</th><th>Hopfield</th></tr>
<tr><td rowspan="4">Entrenamiento</td><td colspan="2">Supervisado</td><td>No supervisado</td></tr>
<tr><td>Corrección de error (regla delta)</td><td>Corrección de error (regla delta generalizada</td><td>Hebbiano</td></tr>
<tr><td colspan="3">Offline</td></tr>
<tr><td colspan="2">Varias iteraciones (por patrón)</td><td>Una iteración (por patrón)</td></tr>
<tr><td rowspan="4">Tipo y arquitectura</td><td colspan="2">Heteroasociativa</td><td>Autoasociativa</td></tr>
<tr><td>1 capa (1 neurona)</td><td>2 o más capas</td><td>1 capa</td></tr>
<tr><td colspan="2">Conexiones hacia adelante</td><td>Conexiones laterales</td></tr>
<tr><td colspan="3">Salida: vector</td></tr>
<tr><td rowspan="2">Funcionamiento</td><td colspan="2">Una iteración</td><td>Varias iteraciones</td></tr>
<tr><td colspan="3">Salida discreta o continua</td></tr>
</table>

Emparrillado (lista)

- Es una técnica de educción del conocimiento
- Cada individuo ve al mundo de manera diferente
- Trabaja sobre un área de interés

Es un test de clasificación en el cual se vincula una lista de elementos homogéneos y representativos sobre la base de un conjunto bipolar de características. Esta bipolaridad estará dada por un conjunto de valores, y a partir de aplicar esta técnica sobre todos estos componentes lograremos extraer la similitud de un conjunto de elementos y la diferencia de éste conjunto con otros.

- Describe elementos del dominio
- Los ubica en su imaginario
- Tiene en cuenta aspectos importantes

Ventajas

- Reflexión tema
- Representación gráfica
- Asociaciones entre elementos y características
- Refina problema y mejora el conocimiento

Inconvenientes

- Valores subjetivos
- Captura conocimiento superficial
- Complejo en gran cantidad de elementos y/o características

- Solo no es útil para Base de Conocimiento

Etapas del emparrillado

- Identificación de los elementos
- Identificación de las características
- Diseño de la parrilla
- Formalización
- Interpretación o análisis de resultados

Identificación de los elementos

Los elementos deben ser representativos y homogéneos, separables y no solapados. Ejemplo:

E1: Coronavirus COVID-19
E2: Coronavirus MERS-CoV
E3: Coronavirus SARS-CoV
E4: Coronavirus 229E

Identificación de las características

Cualidad atribuida a un elemento o concepto de pensamiento. Valores: bipolares (alto – bajo)

C1: Frecuencia respiratoria (alta/baja)
C2: Fiebre (alta/baja)
C3: Intensidad del dolor de garganta (intenso/leve)
C4: Intensidad del dolor de cabeza (intenso/leve)

Diseño de la parrilla

Se debe enlazar elementos y características. Usamos:

Matriz bidimensional que puede ser de los tipos:

- Dicotómica: valores binarios {0, 1} (elemento posee o no la característica)
  Ej: 0 → no tiene la característica, 1 → tiene la característica
- Clasificatoria: [1, n] – "n" es el número de elementos
  Cada relación (elemento, característica) valor M (indica que posición ocupa el elemento dentro del rango total – se da orden – no empate)
- Evaluativa: [1, n] - "n" no necesariamente tiene relación con la cantidad de elementos.
  Cada relación (elemento, característica) valor de acuerdo al grado de satisfacción con que el elemento en cuestión cubre la característica

En nuestro ejemplo, usamos una evaluativa, con una escala de [1, 4]

	E1	E2	E3	E4
C1	2	4	3	2
C2	3	2	2	3
C3	1	3	4	1
C4	4	1	2	2

Formalización

Clasificación de los elementos

Se halla otra matriz, llamada la matriz de distancia de los elementos. Se calcula tomando distancia entre cada uno de los elementos.

E1 Y E2 = ∑ [|2-4| + |3-2| + |1-3| + |4-1|] = 2 + 1 + 2 + 3 = 8

	E1	E2	E3	E4
C1	2	4	3	2
C2	3	2	2	3
C3	1	3	4	1
C4	4	1	2	2

E2 Y E3 = ∑ [|4-3| + |2-2| + |3-4| + |1-2|] = 1 + 0 + 1 + 1 = 3

	E1	E2	E3	E4
C1	2	4	3	2
C2	3	2	2	3
C3	1	3	4	1
C4	4	1	2	2

Hacemos esto con todas, terminando con una matriz triangular superior:

	E1	E2	E3	E4
E1		8	7	2
E2			3	6
E3				5
E4				

De los valores, tomamos el mínimo valor (o el máximo, si usamos como criterio el máximo).

	E1	E2	E3	E4
E1		8	7	**2**
E2			3	6
E3				5
E4				

Lo que vamos a hacer es fusionar E1 y E4, y volvemos a calcular las distancias. Pero ahora, usando como criterio el mínimo:

[E1, E4] Y E2 = min [(E1, E2) Y (E4, E2)]

= min (8, 6)

= 6

Repetir con todos los demás y quedarse con el menor

	[E1, E4]	E2	E3
[E1, E4]		6	5
E2			3
E3			

	[E1, E4]	[E2, E3]
[E1, E4]		5
[E2, E3]		

Con todo esto calculado, se construye el árbol:

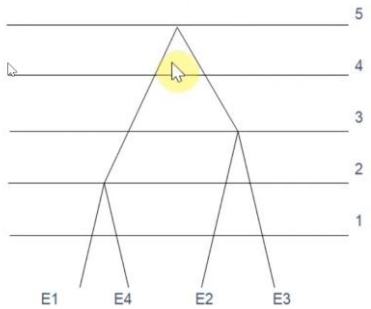

Clasificación de las características

Se usa una parrilla opuesta. Para obtenerla, se invierte la escala de valores. 1-2-3-4 → 4-3-2-1

Parrilla original:

	E1	E2	E3	E4
C1	2	4	3	2
C2	3	2	2	3
C3	1	3	4	1
C4	4	1	2	2

Parrilla opuesta:

	E1	E2	E3	E4
C1	3	1	2	3
C2	2	3	3	2
C3	4	2	1	4
C4	1	4	3	3

Pero antes, se calcula la distancia (en la matriz original) pero ahora usando las filas

C1 Y C2 = ∑ [|2-3| + |4-2| + |3-2| + |2-3|] = 1 + 2 + 1 + 1 = 5

	C1	C2	C3	C4
C1		5	4	6
C2			7	3
C3				8
C4				

Ahora, debemos calcular la distancia d2 para la triangular inferior, y se hace tomando un elemento de cada parrilla.

C1 Y C2 = ∑ [|2-2| + |4-3| + |3-2| + |2-2|] = 0 + 1 + 0 + 0 = 1

	C1	C2	C3	C4
C1		5	4	6
C2	1		7	3
C3	8	3		8
C4	2	5	4	

Para ahora si calcular la diagonal superior para criterio de mínima distancia, se comparan los opuestos y se toma el menor:

	C1	C2	C3	C4
C1		5	4	6
C2	1		7	3
C3	8	3		8
C4	2	5	4	

	C1	C2	C3	C4
C1		1	4	2
C2			3	3
C3				4
C4				

Y de esta resultante ahora si procedemos de la misma manera que para los elementos

	[C1, C2]	C3	C4
[C1, C2]		3	2
C3			4
C4			

[C1,C2] Y C3 = MIN [(C1, C3) Y (C2, C3)] = MIN (4, 3) = 3

Entonces, resulta:

	[(C1, C2), C4]	C3
[(C1, C2), C4]		3
C3		

Quedando el árbol de características:

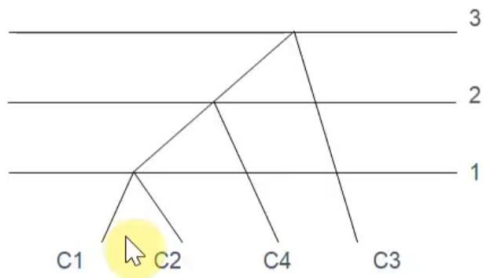

Interpretación o análisis de resultados

Análisis y discusión de árboles ordenados

Análisis árbol de <u>elementos</u> de mínimas distancias

En el árbol se observan dos grupos.

El primer grupo está formado por los elementos E1 y E4, mientras que el segundo grupo está formado por E2 y E3.

Los elementos E1 y E4 son muy similares desde el punto de vista del experto ya que tienen una distancia de 2, al igual que los elementos E2 y E3 con una distancia de 3.

Análisis árbol de <u>características</u> de mínimas distancias

En el árbol se observan tres grupos. El primer grupo está formado por las características C1 y C2, el segundo grupo por la característica C4 y el último por la característica C3. Las características C1 y C2 son muy similares desde el punto de vista del experto ya que tienen una distancia de 1.

Red de relaciones entre características

Tipos de relaciones tipificadas:

- Paralela
- Recíproca
- Ortogonal
- Ambigua

Solo se pueden relacionar características que armen un grupo.

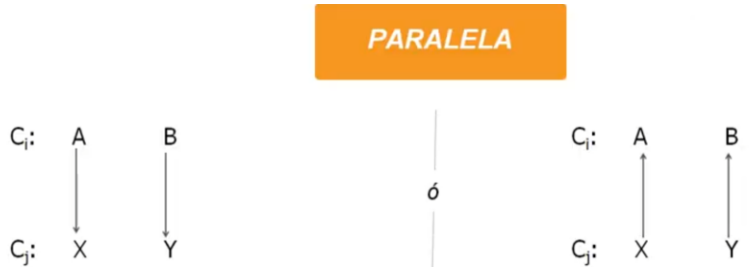

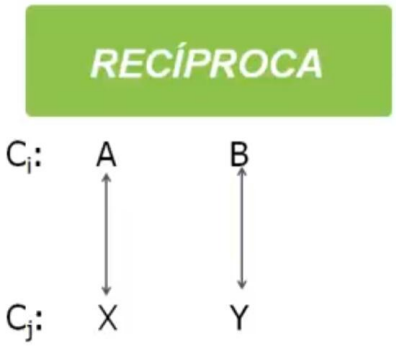

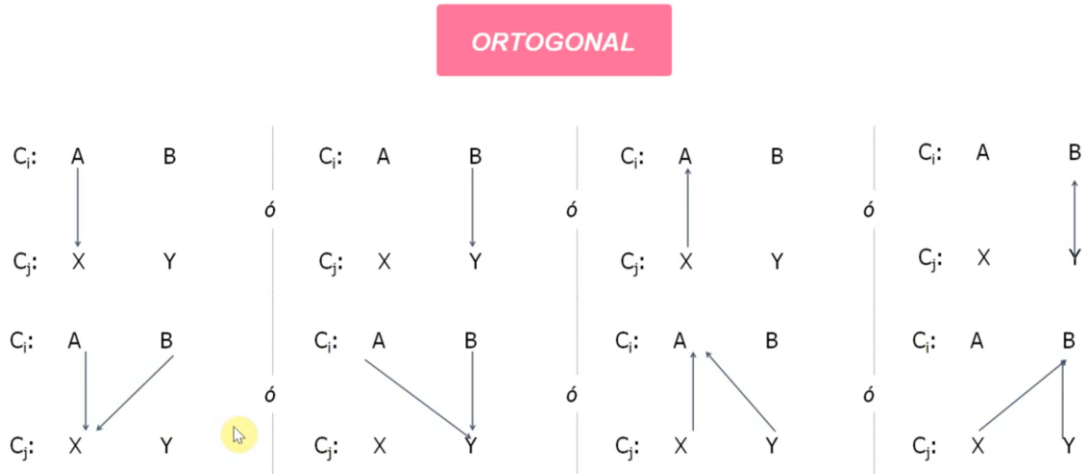

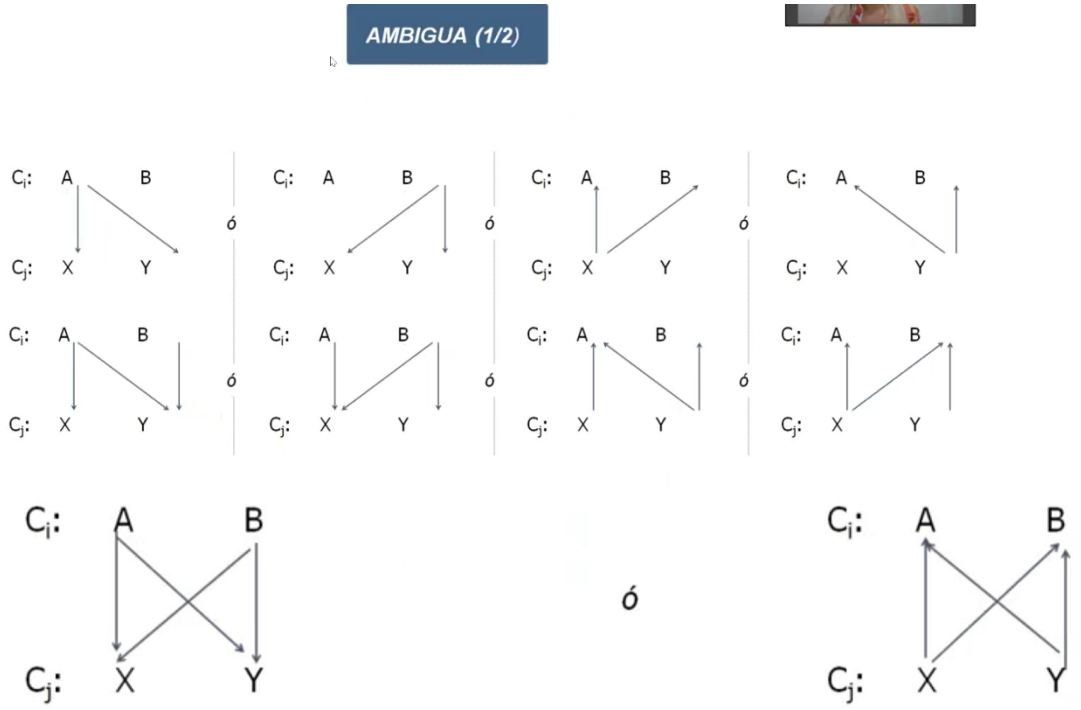

Si el texto dijese:

“En las observaciones realizadas a diferentes pacientes, se puede apreciar que aquellos coronavirus que se manifiestan con frecuencia respiratoria alta, se caracterizan por presentarse con fiebre alta también, mientras que en aquellos que se manifiestan con frecuencia respiratoria baja poseen fiebre baja también”.

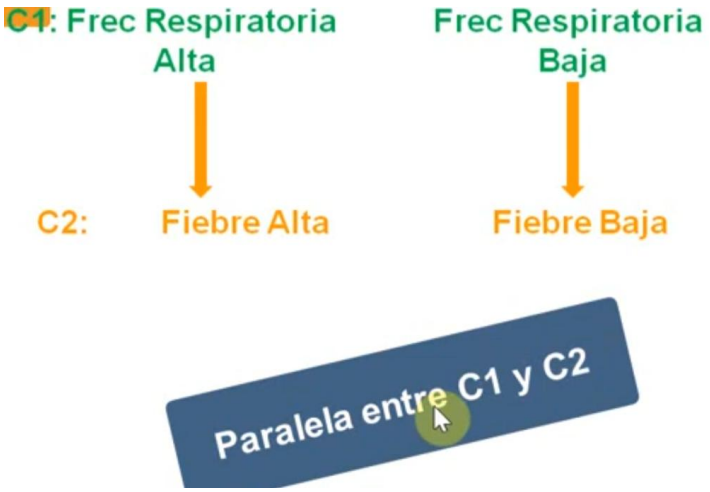

Métodos de búsqueda (lista)

Dado un problema, el primero paso hacia desarrollar un sistema inteligente que pueda resolver debe ser poder modelar el problema de una manera formal a partir de su descripción informal.

Una vez formalizado se debe definir al mismo en términos de una búsqueda en un espacio de estados: inicial, intermedios y finales o solución; podemos pensar al estado como una foto en un momento determinado.

También existen los operadores o reglas que vinculan dos estados posibles, un estado padre a un estado hijo.

Por ejemplo, podemos representar un problema:

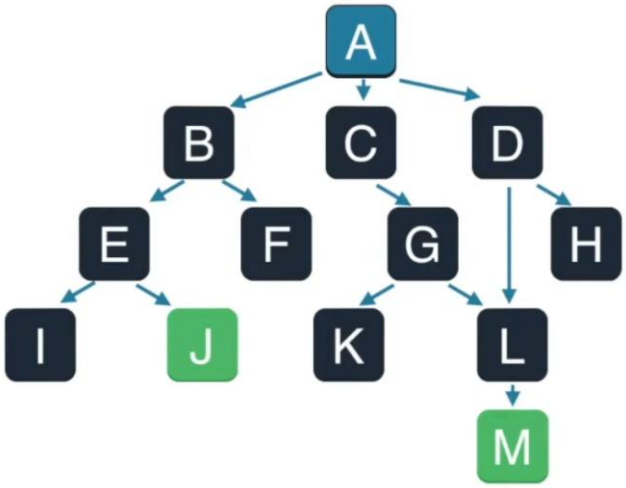

Estado inicial {A}

Estados intermedios = {B, C, D, E, F, G, H, I, K, L}

Estados finales = {J, M}

Con las reglas:

A→B, A→C, A→D, B→E, B→F, C→G, D→L, D→H, E→I, E→J, G→K, G→L y L→M

Proceso de búsqueda para solución de problemas

Lo hacemos a través de una representación del problema, con todos sus componentes y la definición de la estrategia de control.

Esta última es el conjunto de técnicas que nos permiten elegir las distintas reglas o estados a través de los distintos métodos de búsqueda. El proceso de solución de un problema se puede definir como el mecanismo mediante el cual partiendo de un estado inicial se llega a un estado solución, utilizando alguna estructura de control, esta nos permite seleccionar y aplicar las reglas que producen las transiciones entre los estados pertenecientes al conjunto de estados del problema.

Estrategia de control

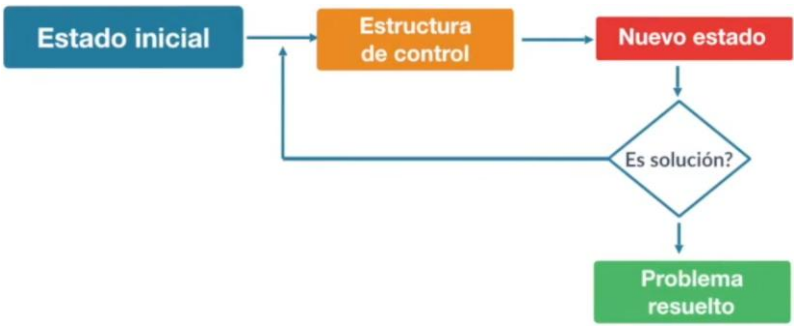

Estructura de control

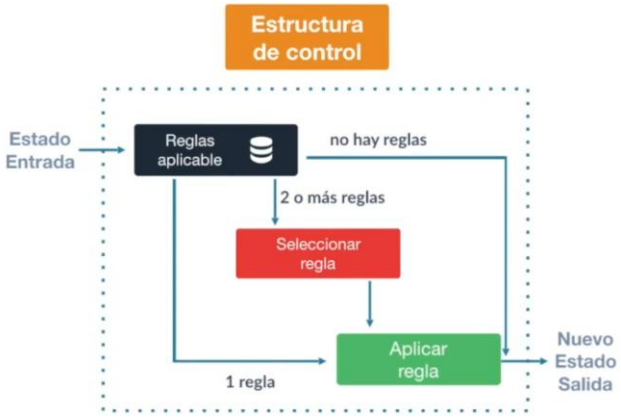

Métodos de búsqueda

Sin información del dominio (o de búsqueda ciega)

No hay información complementaria que diga si un estado es mejor que otro, solo están la descripción propia de los estados y de identificación de los estados solución.

Primero en amplitud

- Aplica el concepto de cola FIFO
- Recorre todos los nodos → si el espacio de búsqueda es finito y existe solución, la encontrará
- Útil cuando existen pocos nodos finales y son cercanos al nodo raíz
- Utiliza mucha memoria

Recorrido de izquierda a derecha:

A, B, C, D, E, F, G, L, H, I, J, K, L, M, M

Recorrido de derecha a izquierda:

A, D, C, B, H, L, G, F, E, M, L, K, J, I, M

Primero en profundidad

- Aplica el concepto de pila LIFO
- No requiere mucha memoria, dado que se expande una rama por vez
- Muy útil cuando existen muchos nodos solución alejados del nodo raíz
- No recorre todo el espacio de búsqueda => no garantiza encontrar la solución óptima

Recorrido de izquierda a derecha:

A, B, E, I, E, J

Recorrido de derecha a izquierda:

A, D, H, D, L, M

Generación y prueba

- Adecuado para problemas sencillos
- Recorre todos los nodos → permite encontrar todos los estados solución
- Problema complejo puede consumir mucho tiempo

Recorrido de izquierda a derecha:

A, B, E, I, E, J, E, B, F, B, A, C, G, K, L, M, L, G, C, A, D, L, M, L, D, H

Recorrido de derecha a izquierda:

A, D, H, D, L, M, L, D, A, C, G, L, M, L, G, K, G, C, A, B, F, B, E, J, E, I

Bidireccional

- Dos búsquedas simultáneas: top-bottom y bottom-up
- Al menos una de estas búsquedas debe ser en amplitud
- Complejidad igual a dos búsquedas unidireccionales para un grafo con la mitad de los nodos del original

Recorrido de izquierda a derecha:

Por profundidad	Por ramas
A	J
B	E
E	B

Resultado: A, B, E, J

Recorrido de derecha a izquierda:

Por profundidad	Por ramas
A	M
D	L
H	D

Resultado: A, D, L, M

Con información del dominio (o de búsqueda heurística)

Hay información propia del dominio donde podríamos analizar los distintos estados intermedios cuando candidatos buenos en pos de estar más o menos cerca de la solución, en base a la definición de su heurística. Aumenta la eficiencia del proceso, sacrificando exhaustividad

Las formas de incorporar conocimiento del dominio son:

- Con una función heurística asociada al estado
- Con el costo de los caminos aplicables. En este caso penalizamos los caminos que no convienen según la heurística

Usamos:

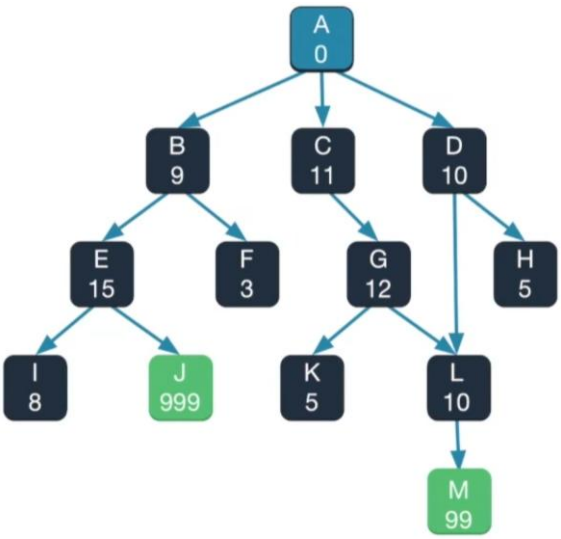

A mayor valor heurístico, más deseable es el nodo.

Escalada simple

Recorrido de izquierda a derecha

- En este caso, a mayor valor heurístico, más deseable es el nodo

Se procede con el primer hijo y nos preguntamos si es mayor al nodo actual. Si es mayor, ese hijo pasa a ser el nodo actual, sino analizamos otro hijo. Si no encontramos ningún hijo, se detiene el recorrido.

Nodos generados: A, B, E, I, J

Nodos visitados: A, B, E, J

- No requieren mucho almacenamiento

- Si existe un sucesor mejor, pude no haberlo encontrado (como este caso, me perdí a C.
- No contempla retrocesos en la búsqueda, por lo que puedo quedar atrapado en un máximo local y puedo tal vez no encontrar una solución

Recorrido de derecha a izquierda

Nodos generados: A, D, H, L

Nodos visitados: A, D

Escalada máxima pendiente

Una vez tengo un nodo actual, generamos a todos los hijos y nos quedamos con el mejor.

Nodos generados: A, B, C, D, G, K, L

Nodos visitados: A, C, G

Primero el mejor

Utiliza dos listas de nodos

- Lista de nodos abiertos: lista de nodos que voy generando, pero que no recorrí
- Lista de nodos cerrados: son los que generé y por los cuales fui recorriendo.

No tiene en cuenta el valor actual para evaluar el valor heurístico de sus hijos. Nunca queda atrapado en un máximo local y puede encontrar siempre una solución, si es que existe.

En este ejemplo se decidió que ante igualdad en el ordenamiento, se pone primero el que estaba antes

Paso	Sub-paso	Valor
1	Nodo actual	A
	¿Es solución?	X
	LNA	C(11), D(10), B(9)
	LNC	A
2	Nodo actual	C
	¿Es solución?	X
	LNA	G(12), D(10), B(9)
	LNC	A, C
3	Nodo actual	G
	¿Es solución?	X
	LNA	D(10), L(10), B(9), K(5)
	LNC	A, C, G
4	Nodo actual	D

	¿Es solución?	X
	LNA	L(10), B(9), K(5), H(5)
	LNC	A, C, G, D
5	Nodo actual	L
	¿Es solución?	X
	LNA	M(99), B(9), K(5), H(5)
	LNC	A, C, G, D, L
6	Nodo actual	M
	¿Es solución?	SI
	LNA	B(9), K(5), H(5)
	LNC	A, C, G, D, L, M

Beam search (N=1)

Es un primero el mejor, pero con limitación de memoria. N es la cantidad máxima de nodos que se albergan en la LNA

Paso	Sub-paso	Valor
1	Nodo actual	A
	¿Es solución?	X
	LNA	C(11), ~~D(10), B(9)~~
	LNC	A
2	Nodo actual	C
	¿Es solución?	X
	LNA	G(12)
	LNC	A, C
3	Nodo actual	G
	¿Es solución?	X
	LNA	L(10), ~~K(5)~~
	LNC	A, C, G
4	Nodo actual	L
	¿Es solución?	X
	LNA	M(99)
	LNC	A, C, G, L
5	Nodo actual	M
	¿Es solución?	SI
	LNA	-
	LNC	A, C, G, L, M

Se comporta de manera similar a escalada de máxima pendiente pero con una diferencia: no necesita evaluar el estado heurístico del hijo comparado con el estado actual

*A**

Incluye también valores en las transiciones

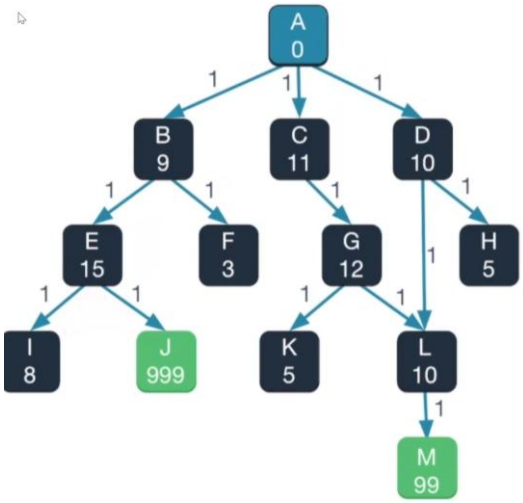

En este caso, como todas las transiciones tienen el mismo valor, podemos interpretar que mientras mas largo es el camino, es menos deseable: ya que se resta su valor heurístico.

Paso	Sub-paso	Valor
1	Nodo actual	A
	¿Es solución?	X
	LNA	C(11-1), D(10-1), B(9-1)
	LNC	A
2	Nodo actual	C
	¿Es solución?	X
	LNA	G(12-1-1), D(9), B(8)
	LNC	A, C
3	Nodo actual	G
	¿Es solución?	X
	LNA	D(9), B(8), L(7), K(2)
	LNC	A, C, G
4	Nodo actual	D
	¿Es solución?	X
	LNA	B(8), L(8), H(3), K(2)
	LNC	A, C, G, D
5	Nodo actual	B
	¿Es solución?	X
	LNA	E(13), L(8), H(3), K(2), F(1)
	LNC	A, C, G, D, B
6	Nodo actual	E
	¿Es solución?	X
	LNA	J(996), L(8), I(5), H(3), K(2), F(1)
	LNC	A, C, G, D, B, E
7	Nodo actual	J
	¿Es solución?	SI
	LNA	L(8), I(5), H(3), K(2), F(1)
	LNC	A, C, G, D, B, E, J

Comparación

Sin información de dominio

Método	**Recorre por...**	**Finaliza cuando...**
Primero en amplitud	Niveles	Recorre todo el árbol
Generación y prueba	Ramas	Encuentra el primer estado final
Primero en profundidad	Ramas	Encuentra el primer estado final
Bidireccional	Niveles (al menos 1)	Encuentra estado intermedio común entre estado inicial y estado final

Con información de dominio

Método	**Recorre por...**	**Finaliza cuando...**
Escalada simple	Ramas	Encuentra el primer estado final
Escalada máxima pendiente		
Primero el mejor		
Beam search		
A*		

Features	**¿Tiene retroceso?**	**¿Garantiza encontrar estado final?**	**Criterio selección siguiente estado**	**Características especiales de la selección**
Escalada simple	No	No	Primer mejor hijo generado por nodo actual	Solo seleccionan hijos que tengan heurística mejor que el padre (nunca con igual valor)
Escalada máxima pendiente	No	No	Mejor de todos los hijos del nodo actual	
Primero el mejor	Si	Si	Mejor nodo abierto	El nodo seleccionado puede no ser mejor que el actual
Beam search	Depende	No	Mejor nodo abierto	Primero el mejor + LNA limitada
A*	Si	Si	Mejor nodo abierto	Primero el mejor + costo de transiciones

Lógica (lista)

Solo me vi la lista pero no anoté nada xdxdxd, confío en el resumen

Razonamiento aproximado y lógica difusa (lista)

Razonamiento aproximado

Son modelos que tratan de imitar la manera en que las personas toman decisiones. Para ello, aplican métodos para representar, combinar y propagar información imprecisa y/o incierta la cual es utilizada en inferencias que tienen asociado un grado de certeza.

- Incertidumbre:
    1) Falta de seguridad, de confianza o de certeza sobre algo, especialmente cuando crea inquietud
    2) Estado de duda en el que predomina el limite de la confianza o la creencia en la verdad de un determinado conocimiento
    3) La imperfección en el conocimiento sobre el estado o los procesos de la naturaleza

Ejemplos: juegos de azar, juegos de cartas, la bolsa

- Imprecisión:
    1) Vaguedad o desconocimiento del valor concreto de una variable
    2) Cualidad generalmente asociada a la incertidumbre aunque puede ser independiente
    3) Falta de precisión ~~o exactitud~~

Ejemplos: un vaso a la mitad, en optimista: el vaso está medio lleno, en pesimista: el vaso está medio vacío

- Fuentes de imprecisión e incertidumbre
    1) Características del mundo real: complejo, no determinista, falta de evidencias, excepciones
    2) Deficiencias de la información: incompleta, errónea, contradictoria
    3) Deficiencias del lenguaje o de los modelos
- Tratamiento de la incertidumbre
    1) Métodos cualitativos: no pueden considerar los grados de certeza de las hipótesis ni manejar muchas combinaciones (se utiliza para la fundamentación teórica pero no en aplicaciones prácticas)
        - Razonamiento por defecto
        - Sistemas de suposiciones razonadas
        - Teoría de justificadores

2) Métodos cuantitativos o numéricos:
    - Método probabilista clásico
    - Modelo de factores de certeza
    - Lógica difusa
    - Modelos de Markov
    - Redes Bayesianas

Lógica difusa

Es mecanismo del razonamiento aproximado que proporciona una manera simple y elegante de obtener una conclusión a partir de datos de entrada vagos, ambiguos, imprecisos, con ruido o incompletos.

La lógica tradicional tiene 2 posibles valores: verdadero o falso

La lógica polivalente posee tres o más posibles valores, como incluir un 0.5 para decir "está lloviendo masomenos". A más posibilidades, complica la implementación. Para eso apalear eso, aparece la lógica difusa:

- No utiliza valores discretos.
- Define una función de pertenencia de un valor al conjunto que puede poseer valores en el rango: [0,0; 1,0] donde 0,0 es falsedad absoluta y 1,0 es verdad absoluta
- Está basada en el concepto de Conjunto Difuso que es un grupo de cosas que no puede ser definido precisamente debido a la naturaleza vaga e imprecisa del concepto
- Para realizar evaluaciones borrosas, se define el grado de pertenencia de un elemento mediante la función de pertenencia $\mu_A(x)$
  Donde:
  1) $\mu_A(x) = 0{,}00$: no pertenencia
  2) $0{,}00 < \mu_A(x) < 1{,}00$: grados intermedios de pertenencia
  3) $\mu_A(x) = 1{,}00$: pertenencia total
- Por lo tanto:
  1) <u>No</u> existe una transición abrupta entre pertenencia y no pertenencia
  2) La función de pertenencia <u>no</u> tiene un sentido probabilístico

Operadores lógica difusa

- Negación:
  $\neg A = A'$
  $\mu_A(x) = | 1 - \mu_A(x) |$
- Disyunción:
  $A \vee B = A \cup B$
  $\mu_A \cup \mu_B (x) = \max [\mu_A(x); \mu_B(x)]$

- Conjunción:
  $A \wedge B = A \cup B$
  $\mu_A \cap \mu_B (x) = \min [\ \mu_A(x); \mu_B(x)\ ]$
- Implicación
  Si A entonces B = A → B
  1) Determinas las entradas difusas del antecedente A:
     Definir el valor de pertenencia de cada función del antecedente
  2) Aplicar los operadores difusos del antecedente A:
     Resolver todos los operadores para obtener un único grado de pertenencia en el antecdente
  3) Propagar el valor al consecuente B:
     Aplicar el mismo grado de pertenencia del antecedente al consecuencia

Sistemas difusos

Aplican la lógica difusa, para representar los datos imprecisos y para aplicar reglas que pueden considerar esa imprecisión al momento de tomar decisiones.

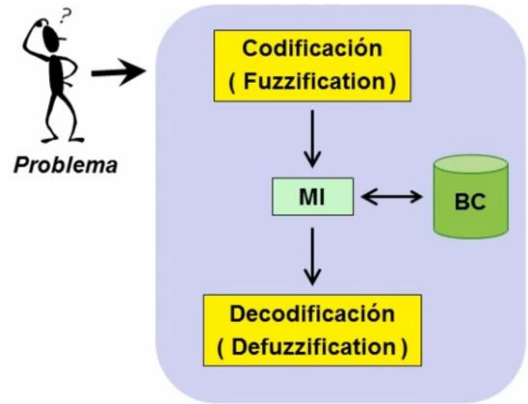

La arquitectura es parecida a un SBC, agregando un módulo de codificación y otro de decodificación. En cuanto a las reglas de la BC, pueden ser de fuentes públicas y privadas. En caso de que sea privado (proveniente de un experto), será un sistema difuso experto. Pueden estar también la memoria de trabajo, trazador de consultas, pero lo simplificamos con esta arquitectura.

- Se utilizan para modelar comportamiento de un sistema real.
- Existen diferentes tipos de modelos para combinar las reglas y generar el resultado correspondiente
- Principales tipos de modelos:
  1) Modelo difuso Mamdani
  2) Modelo difuso Takagi-Sugeno
     el primero es más simple pero requiere de muchas más reglas que

el segundo para resolver problemas complejos o no-lineales con menos reglas

Modelo difuso Mamdani

- Funcionamiento:
  1) Identificar todas las reglas que pueden ser aprendidas
  2) Calcular el valor de pertenencia correspondiente al consecuente de cada regla mediante la aplicación de los operadores de Lógica Difusa
  3) Combinar los valores obtenidos en cada regla para obtener el valor final usando el criterio de:
     - Centro de masa:

$$\text{Salida} = \frac{\sum \ (z_i \cdot \mu_i(z_i))}{\sum \ \mu_i(z_i)}$$

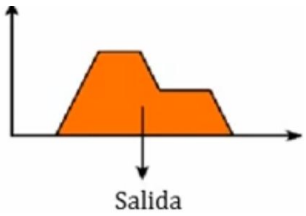

     - Promedio del máximo:

$$\text{Salida} = \sum \left(\frac{z^{\mu Max}{}_i}{\text{cant}_z{}^{\mu Max}} \right)$$

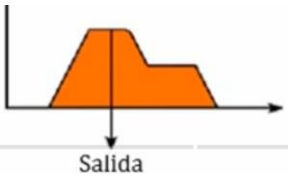

Modelo difuso Takagi-Sugeno

- Funcionamiento:
  1) Identificar todas las reglas que pueden ser aplicadas
  2) Calcular el valor de pertenencia correspondiente al consecuente de cada regla i aplicando una función lineal del estilo:

$$\text{SI} \quad (A_1 = x) \ \& \ (A_2 = y) \quad \text{ENTONCES} \quad B = z$$
$$\mu_i\,(z_i) = a_i \cdot \mu(x) + b_i \cdot \mu(y) + c_i$$

  3) Combinar los valores obtenidos en cada regla usando una media ponderada:

$$\text{Salida} = \frac{\sum \ (p_i \cdot \mu_i(z_i))}{\sum \ p_i}$$

Críticas a sistemas difusos

- Su capacidad de aprendizaje es limitada
- Lógica difusa tiende a funcionar peor que un modelo matemático (pero si no existe es una buena alternativa)
- Al combinar las reglas, no se refuerzan unas a otras. (al aplicar más reglas, la credibilidad de los resultados no se ve reforzada)

Para evitar esto... podríamos prescindir de las reglas y usar un sistema neuro-difuso

Implementación de Sistemas inteligentes (lista)

- Sistemas software tradicional:
    1) Se aplican tareas sistemáticas y procedimentales para manejar datos numéricos
    2) Implementados en forma algorítmica
    3) Deterministas con poca redundancia
- Sistemas inteligentes:
    1) Se aplican en tareas poco conocidas y/o que requieren conocimientos especializados
    2) Implementados en forma declarativa
- Ambos:
    1) Resuelven problemas
    2) Deben satisfacer deseos y necesidades de los stakeholders
    3) Flexibles y robustos

Comparación

Proyecto de construcción →	Software tradicional	Sistema inteligente
Objetivo	Construir un sistema software	Construir un sistema (software) inteligente
Requerimientos	Deseos y necesidades. Características del dominio.	Características de la tarea/problema. Conocimientos(públicos y privados).
Stakeholders	Directivos. Gerentes. Usuarios.	Expertos.*
Tecnología	Hardware. Paradigmas de SW tradicional.	Modelos de IA (como ciencia): Arquitecturas tradicionales. Inteligencia computacional & ML.
Mantenimiento	Correctivo. Adaptativo.	Perfectivo.

Fases de la implementación de un SI

El punto de entrada es la definición del problema, pasando por la identificación y transformación de los datos, para luego seleccionar la tecnología, construir el modelo y por último aplicar el sistema inteligente para resolver el problema.

Definición del problema

Queremos identificar el QUÉ y determinar el CÓMO y esto lo veremos plasmado en el sistema inteligente. Por otro lado, la organización será la fuente de información y las tecnologías posibles por aplicar.

<<QUÉ>>

Hay que definir: metas, expectativas, contexto, necesidades, deseos, restricciones, ...

Áreas problemáticas: información informal, funcionalidades implícitas o no establecidas, suposiciones no fundamentadas o no comunicadas, mala documentación, ...

1. Elicitar los requerimientos

- Identificar las fuentes de información:
    1) Recursos:
        - Propios de la organización: DB, formularios, manuales, políticas, actas de reuniones, ...
        - Externos de la organización: datos públicos, formularios externos, estándares y leyes, libros sobre temas relacionados
    2) Stakeholders:
        - Los 'grupos de interés' formados por los actores (propios o externos) que serán impactados en sus rutinas de trabajo.
        - Se pueden identificar con la estructura formal, pero sin olvidar la informal
- Recolectar los hechos y necesidades
    1) Extracción: análisis de documentación, análisis de datos
    2) Educción: entrevistas, cuestionarios, prototipado, observación y análisis de tareas, tormenta de ideas, reuniones, emparrillado, análisis de protocolos
    3) Recolectar información suficiente para identificar:
       ¿Qué incluye el problema? → Elementos del problema
       ¿Dónde se produce el problema? → Contexto del problema
       ¿A quiénes más afecta el problema? → Nuevos stakeholders
       ¿Por qué es necesario resolverlo? → Metas y expectativas

¿Cómo se manifiesta el problema? → Escenarios
¿Qué puede impedir resolver el problema? → Restricciones

2. Comprender los requerimientos

¿Cómo? Abstraer, descomponer, proyectar y modularizar

- Abstraer:
  1) Ignorar las diferencias entre conceptos similares y así poder agruparlos
  2) Permite:
     - Obtener un panorama general del problema
     - Identificar las características esenciales del problema
     - *Hay que elegir lo que es más importante*
- Descomponer:
  1) Dividir el problema en partes más simples de entender
  2) Permite:
     - Entender cada uno de los elementos principales del problema (junto con sus detalles)
     - *Las partes no suelen ser totalmente independientes*
- Proyectar:
  1) Identificar y describir diferentes visiones de los mismos elementos
  2) Permite:
     - Reconocer patrones entre distintos puntos de vista
     - Identificar conflictos entre stakeholders
     - *Las visiones pueden ser inconsistentes*
- Modularizar:
  1) Combinar los elementos identificados y entendidos en porciones (módulos)
  2) Permite:
     - Delimitar estructuras estables y fáciles de reutilizar
     - Organizar las tareas y grupos de trabajo
     - *Algunos módulos pueden ser más fáciles de manejar que otros*

Las primeras tres actividades van ciclando, es un proceso evolutivo para desembocar en la modularización y allí se generan los modelos conceptuales.

¿Para qué sirve el modelado?

- Entender mejor los requerimientos
- Detectar problemas en los requerimientos: no definidos (ocultos). Mal definidos. Inconsistencias. Confusiones de terminología. Fuera del alcance o no viables. Puntos de conflicto no resueltos.

- Comunicar los requerimientos

Modelos conceptuales:

- Modelos UML
- Árbol de descomposición funcional
- Tablas de decisión
- Árboles de decisión
- Fórmulas
- Pseudo-reglas

3. Articular los requerimientos

Debemos responder: ¿qué se busca resolver? ¿es viable aplicar IA?

¿Qué se busca resolver?

En base a los modelos conceptuales de la actividad 2, vamos a obtener las expectativas, los deseos y necesidades, las restricciones y las suposiciones.

A partir de estos, vamos a poder definir los objetivos, los criterios de éxito y los riesgos. Siendo:

Objetivos: todo lo que la aplicación de IA debería hacer para cumplir las expectativas, deseos y necesidades considerando las restricciones.

Criterios de éxito: todo lo que se debe cumplir para considerar que el proyecto ha sido exitoso (detallado con métricas objetivas)

Riesgos: todo lo que puede afectar la realización del proyecto

Este tridente hace al alcance del proyecto, que es la delimitación de todo lo que se considera como parte del proyecto.

¿Es viable aplicar IA?

Alcance del proyecto: debe ser establecido con cuidado para que tenga sentido usar IA.

- Analizar si IA es posible de ser aplicada para cumplir los objetivos
- Analizar si IA es la mejor alternativa para cumplir los objetivos
- Analizar si se justifica aplicar IA para cumplir los objetivos

4. Formalizar la propuesta de solución

Definido el alcance de proyecto, formalizamos indicando el objetivo, las pre y las post-condiciones y para cada tarea que debemos realizar para cumplir con el objetivo, se detalla su propósito, entradas, acciones y salida.

Tipos de acciones de las tareas:

- Optimización: encontrar una combinación de valores que maximice (o minimice) una función matemática.
- Clasificación: determinar la clase que corresponde a un elemento entre 2 o más opciones
- Predicción: determinar un posible comportamiento futuro (suele tener asociado cierto grado de incertidumbre)
- Regresión: encontrar una función matemática que represente el comportamiento de ciertos valores numéricos
- Clustering: ¿cómo conviene agrupar? Identificar grupos de elementos con características similares.
- Reglas de asociación: inferir condiciones que representen la relación existente entre algunas características
- Detección de anomalías: identificar elementos que tienen comportamientos diferentes al resto
- Generative: generar texto, imágenes u otros medios en respuesta a ciertos datos de entrada
- ...

Identificación y transformación de los datos

Algunas definiciones:

- Dato: toda aquella información concreta asociada al problema la cual se encuentra generalmente en forma estructurada como una tabla
- Columna / atributo: una propiedad o característica de una instancia utilizada para resolver el problema
    1) Tiene atributos de entrada
    2) Atributo clase, objetivo o etiqueta
- Fila / tupla / ejemplo: una instancia con sus atributos y valores

1. Recolectar los datos disponibles

- Principales fuentes de datos: Bases de datos transaccionales. Planillas de cálculo. Logs. Informes estadísticos. Datos de acceso público. Datos generados “en base a heurísticas”. Datos generados por otros SI.
- Al momento de acceder a las fuentes de datos. Se debe analizar:
    - ¿es confiable? ¿quién los crea? ¿quién los modifica? ¿quién los usa?
    - ¿sus datos son muy viejos? ¿se siguen actualizando?
    - ¿es muy costoso accederla? ¿la utilidad de sus datos lo justifica?
- Al recolectarlos se deben considerar restricciones:
    - De privacidad
    - Operativas
    - Técnicas

- Es recomendable siempre gestionar las versiones de los datos recolectados.

2. Estudiar los datos disponibles

Buscamos determinar:

- ¿Cuántos datos se van a necesitar?
- ¿Hay que usar todos los atributos? ¿son todos relevantes para los objetivos?
- ¿los datos tienen ruido y/o errores? ¿valores duplicados? ¿valores sin definir?
- ¿son suficientemente representativos para cumplir los objetivos?
- ¿pueden generar algún tipo de sesgo?
- ¿cómo conviene prepararlos?

3. Preparación de los datos

Es necesario integrar, formatear y limpiar. Esta etapa conviene planificarla, porque puede requerir mucho esfuerzo.

- Integración: busca unificar los datos en una única tabla para facilitar su administración y uso
- Limpieza: incluye la corrección de valores nulos, incompletos, con errores o ruido. En columnas/atributos y filas/ejemplos.
  Algunas posibles acciones incluyen: asignar nuevo valor. Eliminar ejemplo y/o atributo.
- Formateo:
  - Tipos de atributos:
    - Atributos continuos (numéricos): valores binarios. Números enteros. Números con decimales
    - Atributos discretos (no numéricos): valores lógicos. Valores alfanuméricos. Valores fecha y hora
  - Crea nuevos atributos:
    - Para cambiar el tipo de valor
    - Para normalizar los valores
    - Para representar combinación de otros atributos
  - Cambiar el tipo de valores:
    - Atributo continuo → Atributo discreto
      - Discretizando con distintos criterios
    - Atributo discreto alfanumérico → Atributo continuo
      - Asignar código numérico único a cada valor
      - Generar un atributo binario por cada valor
    - Atributo discreto fecha/hora → Atributo continuo

        - Separar en elementos más simples (día, mes, etc)
        - Calcular cantidad en alguna unidad (años, meses, días, etc) desde un momento definido
        - Asignar representación de la fecha y asignar código numérico (día de semana, fin de semana, estación del año, etc.)
    - Normalización / estandarización de atributos numéricos

Con estas actividades, obtenemos los datos para el sistema inteligente para poder entrar en la base de selección de tecnología.

Selección de la tecnología

Seleccionar entre IA tradicional y la Inteligencia computacional & ML.

Para hacer una preselección para cada uno de los módulos que conformen el sistema inteligente podemos encontrar:

- Si se desea aprender automáticamente de datos que se encuentran disponibles: ML
- Si no hay datos disponibles, pero hay reglas representativas: ML, IA tradicional, Inteligencia computacional
- Si no hay datos ni reglas, pero existen heurísticas: Inteligencia computacional

<table>
<tr><th>Tarea</th><th>Machine Learning</th><th>IA Tradicional</th><th>Intelig. Comput.</th></tr>
<tr><td>Optimización</td><td>-</td><td rowspan="3">-</td><td rowspan="2">Algoritmos genéticos</td></tr>
<tr><td>Regresión</td><td>Algoritmos de regresión (ap. supervisado)</td></tr>
<tr><td>Reglas de asociación</td><td rowspan="3">Algoritmos de inducción (ap. no supervisado / supervisado)</td><td rowspan="6">-</td></tr>
<tr><td rowspan="2">Clasificación</td><td rowspan="3">Sistemas basados en conocimientos
&
Sistemas expertos tradicionales</td></tr>
<tr><td rowspan="2">Redes neuronales artificiales (ap. supervisado)</td></tr>
<tr><td>Predicción</td></tr>
<tr><td>Clustering</td><td rowspan="2">Redes neuronales artificiales (ap. no supervisado)</td><td rowspan="2">-</td></tr>
<tr><td>Detección de anomalías</td></tr>
</table>

Construcción del modelo

A cada módulo del sistema inteligente debemos construir el modelo.

Machine learning

Tenemos datos, que alimentan al algoritmo y termina generando el modelo.

Obviamente, al modelo lo tenemos que entrenar: proceso que buscar determinar (aprender) los valores correctos para construir un modelo que representa un conjunto de datos disponibles (ejemplos). El aprendizaje podía ser supervisado o no supervisado; y offline u online.

Sin embargo, los algoritmos de ML pueden tener muchos parámetros. ¿Cómo me aseguro que los parámetros usados generan el modelo óptimo? Respuesta:

Prototipado & Experimentación:

Luego de entrenar el modelo, deberíamos experimentar con el y analizar los resultados, para luego volver a entrenar el modelo.

Validar el modelo: proceso que consiste en evaluar los resultados de diferentes parámetros en el entrenamiento para intentar optimizar el modelo obtenido.

Para esto, es importante tener distintos datos: unos para entrenamiento y otros para validación.

Con esto, nos preguntamos si el modelo tiene buena capacidad de generalizar. Hay que tener cuidado de no sobreentrenar, así que es necesario usar un último proceso, que es **probar**: proceso que busca evaluar si el modelo construido posee una buena capacidad de generalización.

Para esto, incorporamos un último set de datos: los de prueba. Debieran ser parecidos a los de producción.

IA tradicional

Tenemos que identificar reglas y conceptos que se vuelcan en la base de conocimientos. Este último será el modelo para resolver el problema.

Hay que tratar de codificar las reglas, conceptos para que queden registros dentro de mi BdC.

Inteligencia computacional

- Algoritmos genéticos:
    - Cromosoma & Función de aptitud:
        - Modelo simplificado del problema
        - Se deben definir con mucho cuidado
            - Principal fuente de conocimiento
        - No es imprescindible que sean ‘perfectos’ pero si no se corresponden con el problema, entonces el algoritmo va a encontrar la solución correcta para el problema equivocado
    - Cromosoma:
        - Tamaño fijo y longitud mínima posible con poca redundancia (conciso)

        - Todas las posibles soluciones deben estar representadas (completitud)
        - Evitar representar soluciones inválidas (coherencia)
        - Todas las soluciones deben tener la misma posibilidad de ser generadas (uniformidad)
        - Fácil de interpretar (sencillez)
    - Función de aptitud:
        - Utilizar de la mejor manera posible el conocimiento del problema (aplicación de la heurística)
        - Ser consistente con el cromosoma
        - Reducir la influencia del ruido y las perturbaciones (robustez)
        - Pequeños cambios en las características, deben generar pequeños cambios en la valoración (causalidad fuerte o adyacencia)
        - Manejar correctamente la 'penalización' de soluciones inválidas:
            - Pena de muerte
            - Niveles de penas (constantes)
            - Penas adaptativas en el tiempo
            - Penas adaptativas por la aptitud de la población

Aplicación del sistema inteligente

1. Integrar los modelos construidos:

Se realiza a través de canalizaciones o pipelines: consiste en determinar como se ejecutarán en producción todas las acciones relacionadas con el sistema inteligente en forma integrada:

- Recolección de los datos
- Preparación de los datos
- Ejecución del modelo
- Ajuste de resultados del modelo (preparación de los datos)
- …

Regla dorada:

- Siempre realizar en producción las mismas acciones de recolección y preparación de los datos que lo que se hizo durante el desarrollo para la construcción de los modelos
- Sino los modelos se pueden presentar comportamientos no esperados.

2. Integrar con sistemas software externos y usuarios

Es autoexplicativo, vía interfaces. Puedo integrar los sistemas existentes con inteligencia artificial.

3. Instalación

Hacer pruebas de aceptación, probar con datos de producción

4. Monitoreo

Ver que no esté fallando.

5. Mantenimiento

Volver a aplicar las fases de la implementación

PNL (lista)

Áreas fundamentales de lingüística

- Fonología: estudia los fonemas, que son los sonidos distintivos en un idioma, así como los patrones de entonación y acentuación
- Morfología: es el estudio de la estructura de las palabras y de cómo se forman a partir de unidades más pequeñas llamadas morfemas
- Sintaxis: se ocupa de la estructura de las oraciones y de las reglas que gobiernan la combinación de palabras para formar frases gramaticales
- Semántica: es el estudio del significado de las palabras, frases y oraciones en un contexto dado.

Formas de comunicación

- Lenguaje verbal: es una forma de comunicación que utiliza palabras habladas o escritas para transmitir información, ideas y emociones entre individuos.
    - Lenguaje oral
    - Lenguaje escrito
- Lenguaje no verbal: se refiere a cualquier forma de comunicación que no involucre palabras habladas o escritas, sino que se basa en gestos, expresiones faciales, posturas corporales y otros medios no lingüísticos para transmitir información. Como por ejemplo
    - Lenguaje corporal
    - Lenguaje visual
    - Contacto físico
- Lenguaje artificial: se refiere a sistemas de comunicación creados deliberadamente por humanos con el propósito de facilitar la interacción y la transmisión de información en contextos específicos. Como por ejemplo:
    - Lenguaje de programación
    - Lenguaje técnico

- Lenguaje científico

Lenguaje artificial

Para procesar un lenguaje artificial no es necesario contar con un sistema inteligente. Estos lenguajes tienen normas gramaticales estrictas, sintaxis limitadas y, en definitiva, una estructura predecible y procesable

Lenguaje natural

El lenguaje natural se refiere al sistema de comunicación utilizado por los seres humanos para expresar ideas, emociones y experiencias a través de palabras habladas o escritas.

Procesamiento de lenguaje natural

Es un campo de la inteligencia artificial, comparte cosas con machine learning y deep learning. Podemos definirlo como la rama de la inteligencia artificial que se enfoca en la interacción entre las computadoras y el lenguaje humano. Su objetivo es permitir a las máquinas comprender, interpretar y generar lenguaje humano de manera efectiva.

- Análisis de sentimientos: identificar y clasificar las emociones expresadas en un texto
- Traducción automática: convertir texto de un idioma a otro de manera automática y precisa
- Extracción de información: identificar y extraer información específica y relevante de un texto
- Generación lenguaje natural: crear texto coherente de manera automática
- Otros: respuestas a preguntas, clasificación de textos, etc.

Orientaciones de NLP

- Comprensión del lenguaje natural (NLU): técnicas de procesamiento del lenguaje natural que emplean un análisis sintáctico y semántico del texto o el discurso para tratar de comprender el significado de una oración. La sintaxis hace referencia a la estructura gramatical de la oración, mientras que la semántica estudia el significado de cada una de sus palabras y en última instancia de la oración completa
- Generación del lenguaje natural (NLG): técnicas de procesamiento de lenguaje natural que hacen referencia a todos los modelos generativos de lenguaje. En lugar de comprender oraciones, se generan conformando un texto completo en base a una determinada entrada.

Dinámicas

Tokenización, normalización y segmentación

Procesamiento de texto

Consiste en una secuencia de tareas que decantan en un resultado homogéneo del texto con una estructura que facilita la extracción de patrones y realizar predicciones con mayor precisión al momento de procesar lenguaje.

Dentro de las tareas principales de este pipeline se encuentran:

Tokenización

Es el proceso de encontrar los elementos básicos individuales de un texto, habitualmente las palabras. Consiste en dividir un texto en unidades más pequeñas llamadas "tokens", que pueden ser palabras, frases o incluso caracteres.

¿Por qué se realiza?

- Facilita el análisis: al dividir el texto en tokens, se simplifica el análisis y procesamiento de la información
- Indexación y búsqueda: permite la creación de índices para una búsqueda más eficiente
- Estandarización: ayuda a estandarizar el texto, permitiendo un tratamiento uniforme de palabras y frases.
- Mejora el rendimiento: trabajar con tokens, optimiza el rendimiento y la precisión del modelo.

Normalización

La normalización en el NLP es el proceso de convertir diferentes formas de palabras y frases en una forma estándar o común.

¿Por qué se realiza?

- Reducir variabilidad: diferentes formas de una palabra se pueden normalizar a una forma base común
- Estandarización: facilita la comprensión y el procesamiento uniforme del texto
- Mejora precisión: al reducir la variabilidad, se pueden aprender patrones consistentes, mejorando su rendimiento.

Algunas tareas que se realizan en la normalización:

Lemantización: reduce las palabras a su lema, es decir, su forma base o diccionario. Por ej, "correr", "corriendo", "corrió" se normalizan a correr.

Stemming: reduce las palabras a su raíz, la cual representa el núcleo del significado. Por ejemplo, “corriendo”, “corrió” se pueden reducir a “corr”.

Conversión a minúsculas: convertir todo el texto a minúsculas para evitar diferencias entre mayúsculas y minúsculas.

Signos y caracteres: eliminación de signos de puntuación y caracteres especiales: esto ayuda a limpiar el texto y eliminar elementos que no aportan al análisis semántico.

Segmentación

El objetivo de la segmentación es agrupar todos los tokens hallados en una jerarquía de nivel superior, creando agrupaciones de tokens por cada una de las oraciones detectadas como oraciones o párrafos.

¿Por qué se realiza?

- Mejorar la comprensión: al dividir el texto en unidades más pequeñas y coherentes, se facilita su análisis y comprensión
- Eficiencia: genera eficiencia al permitir enfocarse en unidades significativas de información
- Facilitar procesamiento: benefician a los algoritmos de trabajar con oraciones completas y no con fragmentos de texto

Categorización, autocorrección y autocompletado

En el NLP existen técnicas que buscan mejorar la interacción y comprensión del texto por parte de los sistemas inteligentes. Cada una de estas técnicas tiene su propósito específico, pero todas contribuyen a una mejor gestión y manipulación del texto.

Estas técnicas son:

Categorización

Es el proceso de asignar una etiqueta o categoría a un fragmento de texto basándose en su contenido. Se realiza para organizar y clasificar el texto de manera eficiente, facilitando la organización y la búsqueda de información relevante dentro de grandes volúmenes de texto, mejorando así la eficiencia en el manejo de datos textuales.

¿Cuáles son las categorías?

- Categorías léxicas: son categorías que están en constante cambio y crecimiento, y pueden surgir nuevas palabras pertenecientes a estas clases en cualquier momento. Se las denominan Open Classes y son: sustantivos, adjetivos, verbo y adverbio.

- Categorías funcionales: son categorías que no tienen probabilidad de que surjan nuevas palabras de estos tipos, consideradas Closed Classes. Como ser: pronombres, preposiciones, conjunciones, interjecciones, determinantes, signos y símbolos.

Autocorrección

El objetivo de la autocorrección es transformar palabras incorrectamente escritas en sus versiones correctas, mejorando la calidad del texto y la eficiencia de la comunicación. Es comúnmente utilizada en sistemas de mensajería, editores de texto y correos electrónicos.

Funcionamiento de autocorrección

1. Identificar errores: el sistema identifica una palabra que no pertenece al vocabulario predefinido. Esto se logra comparando cada palabra escrita con un diccionario.
2. Propuesta de correcciones: detectada una palabra incorrecta, se buscan las palabras más cercanas en el vocabulario conocido. La cercanía se mide utilizando algoritmos de distancia de edición (ej. algoritmo de Levenshtein)
3. Sustitución de palabras: la palabra errónea se sustituye por las palabras encontradas a una distancia determinada.
4. Selección mejor opción: se calculan las probabilidades de cada una de las palabras propuestas en función del contexto de la oración y se sugiere la palabra con mayor probabilidad.

Autocompletado

El objetivo del autocompletado es predecir y sugerir las siguientes palabras en una secuencia de texto mientras el usuario escribe, con el fin de ahorrar tiempo y mejorar la eficiencia de la escritura. Es comúnmente utilizado en teclados predictivos, motores de búsqueda y asistentes de texto.

Funcionamiento de autocompletado

1. Recopilación de datos: el sistema recopila datos de texto, ya sea a partir de documentos, conversaciones o búsquedas anteriores, para construir un corpus de lenguaje.
2. Modelado del lenguaje: se utilizan modelos de lenguaje para aprender la probabilidad de ocurrencia de las palabras en una secuencia. Un modelo de lenguaje básico es el modelo n-gram.
3. Predicción: dado un contexto (las últimas n palabras escritas), el sistema predice la palabra más probable que seguiría en la secuencia.
4. Sugerencias: el sistema presenta una lista de sugerencias al usuario, quien puede seleccionar la palabra deseada.

NLP tradicional

“Enfoque tradicional del NLP”: es el resultado de la interacción entre ciencia de la computación, que aporta métodos para procesar datos de manera eficiente, y lingüística, que proporciona el conocimiento necesario para interpretar el lenguaje humano y alcanzar tareas elementales con un enfoque tradicional, como ser:

- Dividir el texto en palabras (tokens) u oraciones.
- Reducir (normalizar) palabras a su forma base para mejorar la comparación.
- Extraer información estructurada de un texto mediante expresiones.
- Identificar y corregir errores en palabras.

Ventajas

Siguen siendo útiles y eficaces en una amplia gama de aplicaciones, especialmente cuando se busca simplicidad, control y eficiencia sin depender de grandes volúmenes de datos o modelos complejos.

- Simplicidad y transparencia: son simples de ver y ajustar directamente, lo que hace que el proceso sea muy transparente.
- Menos datos: no requiere grandes cantidades de datos de entrenamiento como los modelos de ML o DL.
- Menos recursos: pueden ejecutarse en máquinas menos potentes, lo que reduce la necesidad de infraestructura de alto rendimiento.
- Facilidad de implementación
- Suelen ser más fáciles de implementar y mantener en comparación con los modelos de ML/DL

Limitaciones

Estos métodos tradicionales resultan eficaces en problemas estructurados y controlados, pero a medida que se aplican a escenarios más complejos y abiertos comienzan a mostrar sus limitaciones

1. Ambigüedad léxica y estructural
2. Dependencia entre palabras
3. Falta de contexto

NLP con machine learning

El uso de ML en el NLP surgió como respuesta a las limitaciones de los enfoques tradicionales basados en reglas y modelos estadísticos básicos. A medida que se intentaba abordar problemas más complejos en el lenguaje humano, se hizo evidente que los métodos manuales y las reglas fijas no eran suficientes.

El ML tradicional se refiere a los algoritmos de aprendizaje automático sin redes neuronales profundas (Deep Learning). Se basa en técnicas estadísticas y matemáticas para encontrar patrones en los datos y hacer predicciones.

Algoritmos de ML tradicional

Representación de texto

Objetivo: convierten el texto en vectores numéricos para alimentar los modelos de machine learning tradicional.

TF-IDF: genera representaciones vectoriales considerando la importancia de una palabra en un documento dentro de un corpus.

GloVe: construye un vector que muestra las relaciones semánticas y sintácticas entre palabras mediante distribuciones de coocurrencia.

Modelos de regresión

Objetivo: estos modelos buscan asignar etiquetas o valores numéricos a textos, según la tarea a resolver.

Regresión lineal: predecir un valor numérico continuo a partir de texto. Ejemplo: predicción de la calificación de una reseña basada en su contenido

Regresión logística: clasificar un texto en categorías (especialmente en problemas binarios). Ejemplo: clasificación de sentimientos (positivo/negativo)

Modelos de árboles y ensambles

Objetivo: estos modelos dividen los datos en nodos de decisión para hacer predicciones, principalmente de clasificación.

Árboles de decisión: estructura jerárquica donde cada nodo representa una decisión basada en una característica del texto. Ejemplo: clasificación de sentimientos

Random forest: es un ensamble de múltiples árboles de decisión. Ejemplo: clasificación de noticias (deportes, política, tecnología).

Modelos de clustering

Objetivo: descubrir agrupaciones naturales en textos basándose en similitudes semánticas o estadísticas.

K-Means: es un algoritmo de clustering basado en la distancia entre puntos en un espacio vectorial. Ejemplo: descubrir tópicos en redes sociales.

DBSCAN: encuentra clusters de cualquier forma y puede detectar puntos atípicos o ruido. Ejemplo: análisis de comentarios en plataformas.

Comprensión del lenguaje

El ML tradicional es útil para tareas donde se requiere extraer significado y estructurar información del texto, alcanzando tópicos referidos a la comprensión del lenguaje (NLU) dentro del NLP.

Abarca:

- Análisis semántico
- Análisis sintáctico
- Análisis de sentimiento
- Extracción de información

La evolución de los sistemas inteligentes, en particular NLP, implicó que no solo se construyan modelos que permitan comprender el lenguaje sino también generarlo (GLU) de forma coherente y fluida.

- Generación automática
- Personalización de contenido
- Informes o resúmenes
- Control de estilo y tono